



UNIVERSITAS INDONESIA

**PEMBANGUNAN KORPUS PASANGAN KATA RELASI
HIPERNIM-HIPONIM BAHASA INDONESIA MENGGUNAKAN
PENDEKATAN PATTERN ANALYSIS**

SKRIPSI

**MADE NINDYATAMA NITYASYA
1306381622**

**FAKULTAS ILMU KOMPUTER
PROGRAM STUDI ILMU KOMPUTER
DEPOK
JULI 2017**



UNIVERSITAS INDONESIA

**PEMBANGUNAN KORPUS PASANGAN KATA RELASI
HIPERNIM-HIPONIM BAHASA INDONESIA MENGGUNAKAN
PENDEKATAN PATTERN ANALYSIS**

SKRIPSI

**Diajukan sebagai salah satu syarat untuk memperoleh gelar
Sarjana Ilmu Komputer**

**MADE NINDYATAMA NITYASYA
1306381622**

**FAKULTAS ILMU KOMPUTER
PROGRAM STUDI ILMU KOMPUTER
DEPOK
JULI 2017**

HALAMAN PERNYATAAN ORISINALITAS

**Skripsi ini adalah hasil karya saya sendiri,
dan semua sumber baik yang dikutip maupun dirujuk
telah saya nyatakan dengan benar.**

Nama : Made Nindyatama Nityasya
NPM : 1306381622
Tanda Tangan :

Tanggal : 5 Juni 2017

HALAMAN PENGESAHAN

Skripsi ini diajukan oleh :

Nama : Made Nindyatama Nityasya

NPM : 1306381622

Program Studi : Ilmu Komputer

Judul Skripsi : Pembanguna Korpus Pasangan Kata Relasi Hipernim-
Hiponim Bahasa Indonesia Menggunakan Pendekatan Pattern Analysis

Telah berhasil dipertahankan di hadapan Dewan Penguji dan diterima sebagai bagian persyaratan yang diperlukan untuk memperoleh gelar Sarjana Ilmu Komputer pada Program Studi Ilmu Komputer, Fakultas Ilmu Komputer, Universitas Indonesia.

DEWAN PENGUJI

Pembimbing : Mirna Adriani, Dra, Ph.D. ()

Pembimbing : Rahmad Mahendra, S.Kom., M.Sc. ()

Penguji : ()

Penguji : ()

Ditetapkan di : Depok

Tanggal : 5 Juni 2017

KATA PENGANTAR

Puji dan syukur kehadiran Tuhan Yang Maha Esa karena hanya dengan rahmat-Nya, penulis dapat menyelesaikan pembuatan skripsi ini. Penulisan skripsi ini ditujukan untuk memenuhi salah satu syarat untuk menyelesaikan pendidikan pada Program Sarjana Ilmu Komputer, Universitas Indonesia. Selama menempuh kegiatan penerimaan dan adaptasi, belajar-mengajar, hingga penulisan skripsi ini, penulis tidak sendirian. Penulis ingin berterima kasih kepada :

1. Keluarga penulis
2. Seluruh teman
3. Pembimbing skripsi
4. Dosen pengajar

Depok, 5 Juni 2017

Made Nindyatama Nityasya

HALAMAN PERNYATAAN PERSETUJUAN PUBLIKASI TUGAS AKHIR UNTUK KEPENTINGAN AKADEMIS

Sebagai sivitas akademik Universitas Indonesia, saya yang bertanda tangan di bawah ini:

Nama : Made Nindyatama Nityasya
NPM : 1306381622
Program Studi : Ilmu Komputer
Fakultas : Ilmu Komputer
Jenis Karya : Skripsi

demikian pengembangan ilmu pengetahuan, menyetujui untuk memberikan kepada Universitas Indonesia **Hak Bebas Royalti Noneksklusif (Non-exclusive Royalty Free Right)** atas karya ilmiah saya yang berjudul:

Pembanguna Korpus Pasangan Kata Relasi Hipernim-Hiponim Bahasa Indonesia
Menggunakan Pendekatan Pattern Analysis

beserta perangkat yang ada (jika diperlukan). Dengan Hak Bebas Royalti Noneksklusif ini Universitas Indonesia berhak menyimpan, mengalihmedia/formatkan, mengelola dalam bentuk pangkalan data (*database*), merawat, dan memublikasikan tugas akhir saya selama tetap mencantumkan nama saya sebagai penulis/pencipta dan sebagai pemilik Hak Cipta.

Demikian pernyataan ini saya buat dengan sebenarnya.

Dibuat di : Depok
Pada tanggal : 5 Juni 2017
Yang menyatakan

(Made Nindyatama Nityasya)

ABSTRAK

Nama : Made Nindyatama Nityasya
Program Studi : Ilmu Komputer
Judul : Pembanguna Korpus Pasangan Kata Relasi Hipernim-
Hiponim Bahasa Indonesia Menggunakan Pendekatan Pat-
tern Analysis

Word relation extraction adalah salah satu penelitian dibidang NLP yang bertujuan untuk mengekstrak kata berdasarkan relasi yang didefinisikan. Korpus pasangan kata relasi dibutuhkan untuk menunjang berbagai penelitian selanjutnya. Korpus tersebut umumnya disimpan dalam kamus digital seperti WordNet Bahasa Inggris. Sayangnya untuk Bahasa Indonesia masih banyak kekurangannya. Penelitian ini dilakukan dengan tujuan membangun korpus pasangan kata relasi secara otomatis. Penelitian lain yang sama telah dilakukan dengan berbagai cara. Pendekatan yang dipilih untuk digunakan dalam penelitian ini adalah menggunakan *pattern extrac-tion* dan *pattern matching*. Pembangunan korpus sendiri dilakukan secara bertahap dengan metode *semi-supervised learning*. Relasi yang diteliti adalah relasi semantik hipernim-hiponim dengan menggunakan Wikipedia sebagai data sumber. Pada akhir penelitian, terbentuk korpus dengan total paling banyak 3493 pasangan kata. Akurasi untuk setiap eksperimen yang diujikan selalu lebih besar dari 0.8. Hal tersebut menunjukan bahwa penggunaan metode *pattern* dengan data Wikipedia memiliki potensi untuk menghasilkan data berukuran besar dan berkualitas baik.

Kata Kunci:

relasi kata, *pattern extraction*, *pattern matching*, *semi-supervised*, hipernim-hiponum, korpus

DAFTAR ISI

HALAMAN JUDUL	i
LEMBAR PERNYATAAN ORISINALITAS	ii
LEMBAR PENGESAHAN	iii
KATA PENGANTAR	iv
LEMBAR PERSETUJUAN PUBLIKASI ILMIAH	v
Daftar Isi	vii
Daftar Gambar	x
Daftar Tabel	xi
Daftar Kode	xii
1 PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Perumusan Masalah	3
1.3 Tujuan dan Manfaat Penelitian	3
1.4 Ruang Lingkup Penelitian	3
1.5 Tahapan Penelitian	4
1.6 Sistematika Penulisan	4
2 TINJAUAN PUSTAKA	6
2.1 Leksikal Semantik	6
2.1.1 Word Features	6
2.1.1.1 Ortografi	7
2.1.1.2 Sense	7
2.1.1.3 Word Embedding	7
2.1.1.4 POS Tagging	8
2.1.2 Relasi Kata	8
2.2 Resource Leksikal Semantik	10
2.2.1 WordNet	11
2.2.2 Wikipedia	12
2.2.3 Korpus Pasangan Kata Relasi Semantik	13
2.3 Relation Extraction	14
2.3.1 Semantic Relation Extraction	14
2.4 Pattern Analysis	15
2.4.1 Textual Pattern	16

2.4.2	Pattern Extraction	16
2.4.3	Pattern Matching	17
2.5	Tree Representation	17
2.5.1	Standard Tree	17
2.5.2	Suffix Tree	18
2.6	Semi-Supervised	19
2.6.1	Bootstrapping	19
2.6.2	Meta-Bootstrapping	20
2.6.3	Basilisk	20
2.7	Evaluasi	21
2.7.1	Sampling	21
2.7.2	Precision dan Recall	22
2.7.3	Kappa	22
2.7.4	Spearman's Rho	23
3	RANCANGAN METODOLOGI	25
3.1	Rancangan Pengembangan Korpus	25
3.2	Pre-processing Data	27
3.2.1	Pembentukan Kalimat Wikipedia	27
3.2.2	Pengumpulan Seed	28
3.3	Pembentukan Pattern	29
3.3.1	Sentence Tagging	29
3.3.2	Pattern Extraction	30
3.4	Ekstraksi Pair	31
3.4.1	Pattern Matching	31
3.4.2	Pembobotan dan Filterisasi	32
3.5	Cycle Semi-Supervised	32
3.6	Metode Evaluasi	33
3.6.1	Evaluasi Pattern	33
3.6.2	Evaluasi Pair	34
4	IMPLEMENTASI	36
4.1	Pembentukan Korpus Kalimat Wikipedia	36
4.1.1	Sentence Splitting	37
4.1.2	Rule Based Formatter	37
4.1.3	POS Tagging Kalimat Wikipedia	38
4.2	Seed Builder	39
4.3	Sentence Tagging	40
4.4	Pattern Extraction	41
4.4.1	Informasi dalam Pattern	42
4.4.2	Pattern Tree	43
4.4.3	Vektor Pattern	44
4.4.4	Validasi Pattern	45
4.4.5	Pembentukan <i>Pattern</i> Unik	45
4.4.6	Pengurutan Pattern	46
4.5	Pattern Matching	47
4.5.1	Vektor Pair	49

4.5.2	Filterisasi Pair	49
4.6	Pemodelan Word Embedding	49
5	EVALUASI DAN HASIL	51
5.1	Hasil Pengolahan Data Wikipedia	51
5.1.1	Pengumpulan Data Wikipedia	51
5.1.2	Ekstraksi Teks	51
5.1.3	Pembentukan Kalimat	51
5.1.4	Hasil POS Tagging Kalimat	52
5.1.5	Pemodelan Word Embedding	52
5.2	Pengumpulan dan Evaluasi Seed	52
5.3	Pembentukan Pattern Pertama	53
5.3.1	Sentence Tagging dengan Seed	54
5.3.2	Hasil Pattern Extraction	54
5.4	Hasil Eksperimen	55
5.4.1	Eksperimen 1	55
5.4.2	Eksperimen 2	56
5.4.3	Eksperimen 3	57
5.4.4	Analisis Eksperimen	58
5.5	Hasil Evaluasi Pair	58
5.5.1	Hasil Anotasi Pair	59
5.5.2	Akurasi Pair Berdasarkan Pattern	60
5.5.3	Tingkat Persetujuan Anotator Pair	60
5.5.4	Analisis Pair yang Dihasilkan	61
5.6	Hasil Evaluasi Pattern	62
5.6.1	Pattern Buatan Manual	62
5.6.2	Hasil Anotasi Pattern	64
5.6.3	Tingkat Persetujuan Anotator Pattern	65
5.6.4	Analisis Pattern	66
5.7	Evaluasi Skenario Eksperimen	67
6	KESIMPULAN DAN SARAN	68
6.1	Kesimpulan	68
6.2	Saran	69
	Daftar Referensi	71
	LAMPIRAN	1
	Lampiran 1 : Pattern Buatan Manual	2

DAFTAR GAMBAR

2.1	Contoh Standard Tree	18
2.2	Contoh Suffix Tree	18
3.1	Arsitektur Penelitian	25
3.2	Data XML Wikipedia Dump	27
3.3	Korpus kalimat Wikipedia tanpa <i>POS tag</i>	28
3.4	Korpus kalimat Wikipedia <i>POS tag</i>	28
4.1	Pre-processing Data Wikipedia	36
4.2	Proses Pembentukan <i>Pattern</i>	40
4.3	Contoh <i>pattern tree</i> yang terbentuk	42
4.4	Proses ekstraksi <i>pair</i>	47

DAFTAR TABEL

2.1	Skala pengukuran Kappa	23
5.1	Berkas model <i>word embedding</i>	52
5.2	Jumlah <i>seed</i> hasil ekstraksi	53
5.3	Hasil <i>sentence tagging</i> dengan <i>seed</i>	54
5.4	Pattern terbaik iterasi pertama	54
5.5	Pattern Hasil Eksperimen 1	55
5.6	Pair Hasil Eksperimen 1	56
5.7	Pattern Hasil Eksperimen 2	56
5.8	Pair Hasil Eksperimen 2	57
5.9	<i>Pattern</i> Hasil Eksperimen 3	57
5.10	<i>Pair</i> Hasil Eksperimen 3	57
5.11	Perbandingan hasil anotasi <i>pair</i> antar anotator	59
5.12	Akurasi <i>pair</i> untuk setiap eksperimen	59
5.13	Akurasi <i>pair</i> berdasarkan <i>pattern</i>	60
5.14	Perhitungan tingkat persetujuan anotator berdasarkan label be- nar/salah <i>pair</i>	61
5.15	Perhitungan tingkat persetujuan anotator berdasarkan kategori <i>pair</i>	61
5.16	Kategori <i>pattern</i> sistem dibandingkan dengan <i>pattern</i> manual	63
5.17	Kategori <i>pattern</i> sistem dibandingkan dengan <i>pattern</i> manual	63
5.18	Perbandingan hasil anotasi berdasarkan jumlah <i>pair</i> benar	64
5.19	Perbandingan hasil anotasi berdasarkan jumlah <i>pair</i> salah	64
5.20	Hasil anotasi <i>pattern</i> yang digunakan untuk ekstraksi <i>pair</i>	65
5.21	Cohen's Kappa untuk setiap dimensi	65

DAFTAR KODE

4.1	Penggunaan Wiki Extractor	36
4.2	Algoritme pembentukan <i>seed</i>	39
4.3	Penambahan <i>pattern</i> ke dalam <i>pattern tree</i>	44
4.4	Proses <i>parsing</i> kalimat menjadi <i>array</i>	48
4.5	Kode pembangunan model <i>word embedding</i>	50

BAB 1

PENDAHULUAN

Bab ini membahas mengenai latar belakang penelitian, perumusan masalah, tujuan dan manfaat dilakukannya penelitian, ruang lingkup penelitian, metodologi yang digunakan, dan terakhir sistematika penulisan.

1.1 Latar Belakang

Relasi kata adalah informasi mengenai hubungan yang dimiliki antar satu kata dengan kata yang lain. Informasi mengenai relasi kata sering digunakan untuk menunjang berbagai penelitian, salah satunya adalah *Question Answering* atau sistem tanya jawab. Suatu pertanyaan dapat langsung dijawab jika diketahui hubungan antar suatu kata dalam pertanyaan dengan relasi yang ditanyakan. Sebagai contoh jika diberi pertanyaan ‘Apa ibu kota Indonesia?’ dan dimiliki pengetahuan yang menyimpan relasi ibu-kota(Indonesia, Jakarta), dibaca ‘ibu kota Indonesia adalah Jakarta’, maka pertanyaan tersebut langsung dapat dijawab dengan jawaban ‘Jakarta’.

Selain relasi seperti diatas, beberapa kasus membutuhkan informasi semantik atau makna dari suatu kata untuk dapat menjawab pertanyaan yang diajukan. Relasi yang menghubungkan dua kata berdasarkan semantik kata tersebut dinamakan relasi semantik. Berikut adalah beberapa contoh pertanyaan yang jawabannya memerlukan pengetahuan lebih dalam mengenai arti dari kata dan relasinya.

Pertanyaan: Hewan apa yang senang terbang?

Teks dokumen: Burung cendrawasih senang terbang di antara pepohonan hutan Papua.

Dari teks dokumen yang dimiliki, manusia dapat dengan mudah menjawab pertanyaan yaitu ‘burung cendrawasih’. Hal tersebut karena manusia memiliki pengetahuan bahwa ‘burung cendrawasih’ adalah ‘hewan’. Dilihat dari level semantik, kedua kata memiliki hubungan hipernim-hiponim. Relasi hipernim-hiponim menunjukkan hubungan antara kata yang lebih umum (hipernim) dengan kata yang lebih khusus (hiponim). Dalam Bahasa Inggris, relasi tersebut juga dikenal sebagai *is-a relationship*. Sebagai contoh ‘nasi adalah makanan’ berarti ‘nasi’ adalah hiponim dari ‘makanan’ atau ‘makanan’ adalah hipernim dari ‘nasi’. Dalam kasus di atas, yang menjadi kata hipernim adalah ‘hewan’ sementara ‘burung cen-

drawasih' adalah kata hiponim. Jika sistem menyimpan pengetahuan relasi semantik hipernim-hiponim dua kata tersebut, jawaban dapat langsung diberikan dengan mudah.

Sistem tanya jawab juga memiliki salah satu subbagian lain yaitu *answer type detection*. Proses tersebut berusaha mengidentifikasi tipe jawaban dari pertanyaan sehingga dapat mempercepat proses pencarian jawaban (Jurafsky dan James, 2000). Tipe jawaban dapat dibangun dalam bentuk hirarki atau yang dikenal sebagai *answer type taxonomy*. Sebuah kata dalam pertanyaan mengandung informasi yang dapat mengenali tipe jawaban. Pengetahuan mengenai hirarki hipernim-hiponim kata dapat membantu mempermudah pencarian tipe jawaban. Sebagai contoh diberi pertanyaan 'Buah apa yang berwarna merah?' maka jawaban dari pertanyaan tersebut harus merupakan objek 'buah'. Sistem yang menyimpan seluruh kata hiponim dari 'buah' dapat mempercepat pencarian dengan hanya mengamati kata-kata tersebut. Penelitian sebelumnya telah memanfaatkan relasi hipernim-hiponim kata untuk mengklasifikasikan pertanyaan (Huang et al., 2008).

Dari beberapa kasus yang telah disebutkan, dapat dilihat bahwa pengetahuan mengenai relasi semantik kata, khususnya relasi hipernim-hiponim, penting dan bermanfaat. Dalam Bahasa Inggris, *resource* pasangan kata relasi semantik dapat diambil dari salah satu kamus digital populer yaitu WordNet (Fellbaum, 1998). WordNet tersebut dibangun secara manual oleh berbagai ahli linguistik. Setiap *entry* pada WordNet disimpan dalam bentuk set sinonim atau biasa disebut *synset* dan arti dari *synset* tersebut atau biasa disebut *sense*. *Entry* dalam WordNet juga mengandung informasi mengenai relasi semantik antar *synset*. Penelitian mengenai pembangunan WordNet Bahasa Indonesia telah dilakukan sebelumnya oleh Putra et al. (2008) dan (Noor et al., 2011). Sayangnya jumlah *entry* dalam WordNet Bahasa Indonesia masih sangat terbatas. Selain itu, relasi semantik yang disimpan dalam WordNet Bahasa Indonesia merupakan turunan dari WordNet Bahasa Inggris sehingga dapat dikatakan kurang baik.

Fokus penelitian ini adalah berusaha mengekstrak kata berdasarkan relasi semantik dari suatu dokumen sehingga dapat dibangun korpus pasangan kata relasi secara mandiri. Relasi yang diamati dalam penelitian ini adalah relasi semantik hipernim-hiponim. Penelitian-penelitian sebelumnya yang bertujuan mengekstrak relasi kata hipernim-hiponim telah dilakukan dengan berbagai metode. Pada penelitian ini, metode yang digunakan adalah *pattern-based* yaitu dengan teknik *pattern extraction* dan *matching*. Penelitian ekstraksi relasi kata berbasis *pattern* telah dilakukan oleh Hearst (1992), Ruiz-Casado et al. (2005), dan Arnold dan Rahm (2014). Dokumen yang digunakan sebagai dasar ekstraksi pasangan kata adalah

korpus Wikipedia Bahasa Indonesia. Wikipedia memuat banyak kata dari berbagai domain sehingga dapat dimanfaatkan untuk membuat *pattern* yang general serta menghasilkan korpus berukuran besar.

1.2 Perumusan Masalah

Berdasarkan latar belakang yang telah dipaparkan, pertanyaan yang menjadi rumusan penelitian adalah sebagai berikut.

1. Bagaimana cara membangun korpus pasangan kata relasi hipernim-hiponim berkualitas baik secara otomatis?
2. Seberapa baik metode *pattern extraction* dan *matching* digunakan untuk mengekstraksi pasangan kata relasi semantik Bahasa Indonesia?

1.3 Tujuan dan Manfaat Penelitian

Tujuan dari penelitian ini adalah membangun korpus pasangan kata relasi semantik hipernim-hiponim untuk Bahasa Indonesia berukuran besar dan berkualitas baik secara otomatis. Selain itu, ingin diketahui pula apakah metode *pattern extraction* dan *matching* baik digunakan untuk mengekstrak pasangan kata relasi semantik hipernim-hiponim Bahasa Indonesia. Diharapkan korpus pasangan kata yang dihasilkan dapat menunjang berbagai penelitian lainnya.

Penelitian ini juga diharapkan dapat memotivasi adanya penelitian selanjutnya di bidang *Language Resource Development*, terutama pembangunan WordNet Bahasa Indonesia. Penelitian mengenai ekstraksi pasangan kata relasi semantik berikutnya dengan berbagai metode lain diharapkan terus dilaksanakan sehingga Bahasa Indonesia memiliki *resource* yang semakin baik.

1.4 Ruang Lingkup Penelitian

Penelitian ini berupaya membangun korpus pasangan kata relasi semantik untuk Bahasa Indonesia. Relasi semantik yang diteliti adalah relasi hipernim dan hiponim, dengan kelas katanya yaitu kata benda (*noun* dan *proper noun*). Penelitian ini berusaha mengekstrak tidak hanya kata-kata yang merupakan *single token* seperti ‘komputer’ dan ‘sekolah’, namun juga kata-kata yang merupakan *multi token* seperti ‘bulu tangkis’ serta *noun phrase* seperti ‘mamalia laut’.

1.5 Tahapan Penelitian

Proses penelitian dilakukan dalam beberapa tahapan sebagai berikut.

1. Studi Literatur

Pada tahap ini, dilakukan pembelajaran mengenai penelitian-penelitian terdahulu yang telah dilakukan di bidang *word relation extraction* sehingga diketahui langkah yang perlu diambil selanjutnya.

2. Perumusan Masalah

Perumusan masalah dilakukan untuk mendefinisikan masalah yang ingin diselesaikan, tujuan penelitian, dan hasil yang diharapkan sehingga proses penelitian dapat berjalan dengan baik.

3. Rancangan Penelitian

Setelah diketahui hasil yang ingin dicapai, dirancang tahap-tahap eksperimen secara terstruktur. Hal-hal yang diperhatikan mulai dari pengumpulan korpus awal (*seed*), *pre-processing* dokumen, perancangan implementasi *pattern extraction matching*, hingga proses evaluasi.

4. Implementasi

Implementasi dilaksanakan sesuai dengan rancangan penelitian untuk menjawab rumusan masalah. Segala hasil yang ditemukan digunakan untuk terus memperbaiki metode dan teknik penelitian sehingga didapatkan hasil yang semakin baik.

5. Analisis dan Kesimpulan

Tahap terakhir dari penelitian ini adalah menganalisis korpus pasangan kata relasi yang dihasilkan. Pertanyaan dari perumusan masalah dijawab, kemudian ditarik kesimpulan.

1.6 Sistematika Penulisan

Sistematika penulisan laporan ini adalah sebagai berikut.

- Bab 1 PENDAHULUAN

Pada bab ini, dijelaskan latar belakang topik penelitian. Selain itu, perumusan masalah, tujuan penelitian, ruang lingkup penelitian, serta tahapan penelitian dipaparkan dalam bab ini.

- Bab 2 TINJAUAN PUSTAKA

Bab ini memaparkan teori-teori dasar yang menjadi pedoman penelitian. Seluruh studi literatur mengenai teknik-teknik yang digunakan seperti *pattern matching* dan *extraction*, arsitektur *semi-supervised*, metode evaluasi dan hal-hal mendasar lain yang berhubungan dengan penelitian ini.

- Bab 3 RANCANGAN METODOLOGI

Penjelasan mengenai rancangan metodologi yang digunakan akan dipaparkan dalam bab ini. Arsitektur *semi-supervised* yang diusulkan, penjelasan setiap tahapan, serta masukan dan keluaran tiap tahap dipaparkan untuk memberi informasi mengenai metodologi yang diusulkan.

- Bab 4 IMPLEMENTASI

Bab ini menjelaskan secara spesifik proses implementasi tiap tahap. Seluruh algoritma dan program baik yang digunakan maupun diusulkan dijelaskan secara rinci dalam bab ini.

- Bab 5 EVALUASI DAN HASIL

Hasil dari setiap eksperimen yang telah dilakukan dipaparkan dalam bab ini. Selain itu, evaluasi dan analisis setiap eksperimen dapat memberi gambaran seberapa baik hasil penelitian.

- Bab 6 KESIMPULAN DAN SARAN

Bab terakhir ini akan menyampaikan kesimpulan dari keseluruhan penelitian serta usulan untuk penelitian selanjutnya.

BAB 2

TINJAUAN PUSTAKA

Pada bab ini, dijelaskan mengenai studi literatur yang dilakukan. Studi literatur yang dilakukan digunakan sebagai dasar konsep dan teknik penelitian. Dipaparkan pula berbagai istilah, metode, dan teknik yang digunakan dalam penelitian.

2.1 Leksikal Semantik

Dalam *natural language processing*, terdapat beberapa tingkatan untuk merepresentasikan suatu informasi yaitu kata, sintak, dan semantik. Kata adalah kumpulan simbol yang memiliki arti (*sense*) tertentu. Bentuk kata dasar yang umumnya disimpan sebagai suatu *entry* dalam kamus disebut lema. Sintak berarti struktur dari kata yang bila digabung akan membentuk arti baru. Sementara semantik berarti arti atau makna dari kata itu sendiri. Suatu kata tidak hanya mengandung makna namun juga relasi antar kata serta struktur internal. Leksikal semantik mempelajari arti semantik, sistematis struktur, serta relasi semantik sebuah kata (Jurafsky dan James, 2000).

Lexeme adalah representasi abstrak dari sebuah kata dalam bentuk orthographic yang menyimpan kelas kata dan arti di dalamnya. Lexeme berukuran berhingga tersimpan dalam leksikon atau dapat juga dikenal sebagai kamus. Bahasa Inggris memiliki kamus digital yang menyimpan segala informasi mengenai kata, arti, dan strukturnya yang disebut WordNet¹. WordNet tersebut sering digunakan untuk menunjang berbagai penelitian dalam bidang *natural language processing*.

2.1.1 Word Features

Suatu kata dapat dilihat dari berbagai bentuk, seperti bentuk ortografi, morfologi, maupun fonemik. Suatu kata juga memiliki arti (*sense*) yang merepresentasikan deskripsi terhadap kata tersebut. Sayangnya, tidak semua bentuk kata dapat dikenali oleh mesin atau digunakan untuk proses komputasi. Melalui berbagai penelitian yang telah dilakukan sebelumnya, kata dapat direpresentasikan ke dalam bentuk yang dapat dibaca oleh mesin. Berikut adalah beberapa perbandingan bentuk representasi kata yang bisa dibaca oleh manusia dan mesin.

¹WordNet.princeton.edu

2.1.1.1 Ortografi

Ortografi adalah bentuk paling dasar dari suatu kata. Bentuk ini merepresentasikan rangkaian simbol-simbol yang tersusun membentuk kata yang memiliki arti. Studi mengenai bentuk ini banyak digunakan untuk mengetahui perbandingan ejaan suatu kata. Bentuk dasar kata dapat berubah jika diberi imbuhan dimana hal tersebut dipelajari dalam bidang morfologi kata. Bentuk lain dari kata adalah bentuk fonemik yang melihat bagaimana kata tersebut dilafakan. Karena penelitian ini hanya berfokus pada teks dokumen, maka hanya diperhatikan bentuk orthographic suatu kata.

Sistem umumnya menyimpan bentuk ortografi kata. Bentuk tersebut adalah bentuk paling dasar dibanding yang lain. Walaupun bentuk ortografi kata masih dapat dikatakan sulit digunakan untuk proses komputasi, informasi mengenai bentuk tersebut baik untuk disimpan.

2.1.1.2 Sense

Sense adalah makna atau arti dari sebuah kata. Informasi mengenai makna kata dapat ditemukan dalam kamus (lexicon) bahasa yang bersangkutan. Dalam kamus, kata memiliki arti (*sense*) tersendiri. Informasi mengenai *sense* suatu kata penting karena bentuk kata tidak cukup untuk menggambarkan semantik kata tersebut. Suatu kata yang bentuknya sama dapat memiliki lebih dari satu *sense*. Kata-kata tersebut biasa dikenal dengan istilah polisemi. Sebagai contoh kata ‘halaman’ yang dapat berarti pekarangan rumah atau lembaran buku. Sementara adapula kasus dimana kata yang bentuknya berbeda namun memiliki arti yang sama, seperti kata ‘melukis’ dan ‘menggambar’.

2.1.1.3 Word Embedding

Penelitian ini akan menghasilkan sebuah pasangan kata. Dari pasangan kata tersebut ingin diketahui apakah kedua kata benar berelasi hipernim-hiponim. Sangat sulit bagi mesin untuk mengetahuinya jika hanya bergantung pada bentuk asli kata tersebut. Kata perlu direpresentasikan ke dalam bentuk yang dapat dibaca oleh mesin seperti vektor sehingga dapat dihitung kemiripannya. Mengetahui hal tersebut, digunakan pemodelan *word embedding* untuk mendapatkan representasi kata yang diinginkan. *Word Embedding* atau juga dikenal sebagai *distributed representation* adalah salah satu jenis representasi kata dalam bentuk vektor berdasarkan fitur yang dimiliki oleh kata tersebut.

Pada tahun 2013, diperkenalkan suatu teknik pembentukan *word embedding*

menggunakan korpus teks berukuran besar yaitu Word2Vec Mikolov et al. (2013). Terdapat dua jenis arsitektur dalam sistem tersebut yaitu model *continuous skip-gram* (Skipgram) dan *continous bag-of-word* (CBoW). Kedua pemodelan menggunakan pembelajaran *neural network* sederhana terhadap korpus yang diberikan. Model skipgram memprediksi kata-kata disekitar kata yang diberikan, sedangkan model CBoW memprediksi kata yang diberikan berdasarkan konteks disekitarnya. Implementasi teknik pemodelan tersebut telah dipublikasikan sehingga pembuatan model *word embedding* dapat dilakukan dengan mudah: Word2Vec².

2.1.1.4 POS Tagging

Setiap kata dalam kalimat dapat dikelompokkan berdasarkan kategori tertentu. *Part-of-speech tagging* adalah proses pengelompokan setiap kata dalam suatu kalimat ke dalam kelas kata yang bersesuaian. Kelas kata yang umum dikenal adalah *noun*, *verb*, *adjective*, *adverb*, *conjunction*, dan lainnya. Penelitian lain mengelompokkan kata berdasarkan kelas kata yang didefinisikan sendiri seperti Penn Treebank yang mengelompokkan ke dalam 45 kelas (Marcus et al., 1993) dan Brown korpus yang mengelompokkan ke dalam 87 kelas (Francis dan Kucera, 1979). Informasi tersebut dapat digunakan untuk mendapatkan pengetahuan lebih dalam mengenai suatu kata.

Beberapa penelitian pembangunan *POS tagging* untuk Bahasa Indonesia telah dilakukan sebelumnya oleh Adriani et al. (2009) dan Dinakaramani et al. (2014). Penelitian yang dilakukan oleh Adriani et al. (2009) berusaha melakukan komparasi antara dua metode dalam pembangunan model *POS tagger* yang lebih baik. Sementara penelitian yang dilakukan oleh Dinakaramani et al. (2014) lebih berfokus untuk membangun korpus yang dapat digunakan sebagai model. Penelitian tersebut menghasilkan 23 *tagset* dan korpus Bahasa Indonesia yang telah di-*tag* secara manual. Dari korpus tersebut, model untuk *POS tagging* dapat dibangun dengan bantuan *tools* Stanford POS Tagger (Toutanova et al., 2003).

2.1.2 Relasi Kata

Relasi menggambarkan hubungan yang dimiliki oleh suatu hal dengan yang lain (KBBI). Dalam bidang matematika, relasi memetakan suatu anggota dari himpunan satu ke himpunan lain sesuai dengan hubungan yang didefinisikan. Dalam penelitian ini, relasi yang diperhatikan adalah relasi kata yang berarti satu kata akan

²radimrehurek.com/gensim/models/word2vec.html

dipetakan dengan kata lain. Kemudian, karena relasi yang diteliti adalah hiponim-hipernim, domain katanya adalah kata benda (*noun*) dalam Bahasa Indonesia.

Satu relasi dapat terdiri dari beberapa entitas dan dituliskan dalam bentuk tuple $t = (e_1, e_2, \dots, e_n)$ dimana e_i adalah suatu entitas yang memiliki relasi r dalam dokumen D (Bach dan Badaskar, 2007). Relasi sinonim dapat ditulis dalam notasi tersebut. Selain relasi yang mengandung beberapa entitas, banyak relasi yang hanya menghubungkan antar dua entitas atau biasa disebut relasi biner. Contoh relasi biner antara dua kata adalah ‘terletak-di(Universitas Indonesia, Depok)’, dibaca Universitas Indonesia terletak di Depok, atau ‘ditulis-oleh(Habis Gelap Terbitlah Terang, RA Kartini)’, dibaca Habis Gelap Terbitlah Terang ditulis oleh RA Kartini. Relasi kata dapat didefinisikan secara bebas seperti contoh sebelumnya maupun berdasarkan padanan tertentu seperti relasi semantik.

Semantik adalah arti (*sense*) dari kata. Relasi semantik kata adalah hubungan yang dimiliki antar kata berdasarkan arti atau makna dari kata tersebut. Beberapa relasi semantik kata adalah sebagai berikut (Miller, 1995).

- Sinonim adalah relasi antara kata yang berbeda namun memiliki arti yang sama. Semua kelas kata dapat memiliki relasi sinonim. Relasi sinonim bersifat simetris yang berarti jika ‘sinonim(k_1, k_2)’ benar maka ‘sinonim(k_2, k_1)’ juga benar. Dalam WordNet, relasi ini direpresentasikan dalam bentuk *synset* dan bersifat simetris. Sebagai contoh kata ‘makan’, ‘melahap’, dan ‘menyantap’³ memiliki makna yang sama.
- Antonim menghubungkan dua kata yang memiliki arti yang saling berkebalikan. Umumnya relasi ini dimiliki oleh kata yang berada dalam kelas kata sifat (*adverb*) dan kata keterangan (*adjective*). Sama seperti sinonim, relasi ini memiliki sifat simetris. Sebagai contoh kata ‘tinggi’ memiliki makna yang berkebalikan dengan kata ‘pendek’⁴.
- Hiponim adalah relasi yang menyatakan hubungan kata yang lebih khusus. Sementara untuk kata yang lebih umum dikenal dengan relasi hipernim. Kedua relasi ini diperuntukan kelas kata benda (*noun*) dan umumnya satu kata memiliki hanya satu hipernim. Kedua relasi ini bersifat transitif, sehingga dapat digambarkan dalam bentuk hirarki. Sebagai contoh ‘macan’, ‘singa’, ‘citrah’, dan ‘jaguar’ (hiponim) adalah ‘kucing’ (hipernim)⁵. Kemudian jika

³bahasa.cs.ui.ac.id/iwn/WordNet.php?keyword=makan

⁴compling.hss.ntu.edu.sg/omw/cgi-bin/wn-gridx.cgi?gridmode=wnbahasa&synset=05097536-n&lang=ind&lang2=ind

⁵compling.hss.ntu.edu.sg/omw/cgi-bin/wn-gridx.cgi?gridmode=wnbahasa&synset=02127808-n&lang=ind&lang2=ind

diketahui ‘kucing’ adalah hiponim dari ‘hewan’, dapat pula dikatakan bahwa ‘macan’, ‘singa’, ‘citrah’, dan ‘jaguar’ adalah ‘hewan’.

- Meronim dan holonim adalah relasi yang menyatakan hubungan bagian satu dengan yang lain, dimana meronim menyatakan subbagian dan holonim menyatakan bagian yang lebih besar. Seperti relasi hyponym-hypernym, relasi meronim-holonim bersifat transitif dan dapat digambarkan dalam bentuk hirarki. Dalam WordNet, relasi ini dibagi ke dalam tiga tipe yaitu *part-meronym*, *member-meronym*, dan *substance-meronym*. Sebagai contoh ‘sel’ (holonim) memiliki ‘nukleus’, ‘sitoplasma’, ‘membran’, dan ‘vakuola’ (meronim)⁶.
- *Troponymy* adalah relasi seperti hiponim-hipernim yang khusus untuk kelas kata kerja (*verb*). Dalam Bahasa Inggris, contoh kata yang memiliki relasi ini adalah ‘march’ dan ‘walk’.

Relasi semantik hiponim-hipernim memiliki dua tipe yang lebih spesifik yaitu relasi hiponim-hipernim antar konsep dan relasi hipernim-hiponim antar konsep dan *instance*. Suatu kata disebut sebagai *instance* atau entitas jika wujudnya dapat tergambarkan dengan jelas walaupun tidak harus berbentuk fisik. Sementara konsep atau *class* adalah abstraksi dari suatu kategori yang mengandung sejumlah objek dengan ciri-ciri yang sama. Sebagai contoh pasangan kata relasi hipernim-hiponim antar konsep adalah ‘hiponim(sarapan, makanan)’, dibaca ‘sarapan adalah hiponim dari makanan’. Sementara pasangan kata relasi hipernim-hiponim antar *instance* dan konsep adalah ‘hiponim(Chairil Anwar, penulis)’.

2.2 Resource Leksikal Semantik

Leksikal semantik *resource* adalah suatu korpus yang menyimpan informasi mengenai kata, makna kata, serta relasi antar kata. Leksikal semantik *resource* yang terkenal diantaranya adalah kamus, tesaurus, ensiklopedia, dan WordNet. Informasi tersebut juga perlu disimpan sedemikian sehingga dapat dibaca mesin dan digunakan untuk proses komputasi. Bahasa Inggris sudah memiliki leksikal semantik *resource* yaitu WordNet yang banyak digunakan untuk berbagai penelitian. Sementara untuk Bahasa Indonesia, penelitian yang berusaha membangun WordNet telah dilakukan sebelumnya. Sayangnya masih ditemukan beberapa kekurangan dari WordNet Bahasa Indonesia yang sudah ada.

⁶compling.hss.ntu.edu.sg/omw/cgi-bin/wn-gridx.cgi?username=&gridmode=wnbahasa&synset=00006484-n&lang=ind&lang2=ind

2.2.1 WordNet

WordNet adalah kamus leksikal yang tersimpan secara digital sehingga dapat digunakan untuk berbagai keperluan komputasi (Miller, 1995). Pembuatan WordNet dilatarbelakangi keperluan mendapatkan *sense* atau arti semantik suatu kata. Informasi tersebut perlu disimpan dan dapat dibaca oleh mesin. WordNet pertama dibuat oleh Miller (1995) berbasis Bahasa Inggris dan sekarang dikenal dengan nama Princeton WordNet⁷ (PWN). WordNet menyimpan informasi dalam bentuk *database* dimana setiap *entry* adalah pasangan *synset* dan arti semantiknya (*sense*). Set sinonim (*synset*) adalah himpunan kata yang memiliki arti yang sama atau saling berelasi *synonym*.

Kata dalam WordNet dikelompokkan ke dalam beberapa kelas kata yaitu kata benda (*noun*), kata kerja (*verb*), kata sifat (*adjective*), dan kata keterangan (*adverb*). WordNet juga menyimpan informasi mengenai relasi semantik antar *synset*. Relasi yang disimpan adalah sinonim, antonim, hiponim, hipernim, meronim, holonim, *troponymy*, dan *entailment*. Hingga penulisan ini, versi WordNet yang sudah ada adalah versi 3.1 yang dapat diakses melalui situs resminya maupun diunduh datanya. Sementara bentuk aplikasinya yang sudah terintegrasi dengan sistem UNIX/Linux adalah versi 3.0.

Penelitian mengenai WordNet Bahasa Indonesia pernah dilakukan sebelumnya oleh Putra et al. (2008) serta Margaretha dan Manurung (2008). Indonesian WordNet⁸ (IWN) dibangun menggunakan metode *mapping* antara WordNet yang sudah ada ke dalam Bahasa Indonesia (Putra et al., 2008). WordNet yang digunakan sebagai dasarnya adalah Princeton WordNet. *Synset* dalam PWN akan dipetakan ke dalam *entry* Kamus Besar Bahasa Indonesia (KBBI), sehingga menghasilkan hasil yang berkualitas baik secara cepat dan mudah. Penelitian tersebut menghasilkan 1441 *synset* dan 3074 *sense*. Relasi semantik antar *synset* diperoleh melalui pemetaan antara *synset* IWN dengan *synset* PWN, sehingga relasi yang dikandung oleh PWN dapat diwarisi.

Pengembangan WordNet untuk Bahasa Indonesia juga dilakukan oleh Nanyang Technology University (NTU) sejak tahun 2011 dan diberi nama WordNet Bahasa⁹ (Noor et al., 2011). WordNet ini telah diintegrasikan dengan salah satu *tools* NLP berbasis Python yaitu *nlTK* sehingga dapat dengan mudah digunakan dalam komputasi. WordNet Bahasa juga memanfaatkan PWN untuk memperoleh relasi semantik antar *synset*. Pada penelitian ini, dimanfaatkan *tools* tersebut untuk membangun

⁷WordNet.princeton.edu

⁸bahasa.cs.ui.ac.id/iwn/

⁹wn-msa.sourceforge.net/

seed relasi semantik antar kata dalam Bahasa Indonesia.

Walau beberapa penelitian sudah dilakukan sebelumnya, WordNet Bahasa Indonesia masih memiliki beberapa kekurangan. Jumlah kata yang terkandung di dalamnya masih terbatas. Sementara itu, relasi semantik antar kata yang dimiliki oleh WordNet Bahasa Indonesia merupakan hasil turunan dari relasi semantik WordNet Princeton. Hal ini menyebabkan ketergantungan dengan struktur dari PWN untuk mendapatkan relasi semantik suatu kata. Selain itu, beberapa kata maupun *synset* Bahasa Indonesia juga tidak dapat dipetakan secara tepat ke *synset* PWN yang menyebabkan adanya kata yang kehilangan arti atau mendapat arti yang kurang tepat. Jika dibentuk suatu relasi biner yang memetakan satu kata dengan kata lain berdasarkan relasi semantiknya, hasil yang didapatkan terlihat kurang baik. Untuk itu, dicetuskanlah penelitian untuk mengekstrak relasi semantik dalam Bahasa Indonesia secara mandiri.

2.2.2 Wikipedia

Wikipedia¹⁰ adalah ensiklopedia terbuka yang memuat berbagai bahasa dan merupakan hasil tulisan dari berbagai kontributor (Denoyer dan Gallinari, 2006). Wikipedia adalah salah satu korpus teks dokumen terbesar yang disimpan secara *online* dan dapat diakses serta diunduh secara bebas. Wikipedia dikelola oleh organisasi nonprofit bernama Wikimedia Foundation. Pada tahun 2009, jumlah kontributor Wikipedia Bahasa Indonesia mencapai 2.502 pengguna aktif. Walau ditulis oleh berbagai narasumber, artikel yang dimuat dalam Wikipedia disusun secara terstruktur dan menggunakan bahasa yang cukup formal. Wikipedia juga memuat berbagai informasi umum terbaru (Arnold dan Rahm, 2014).

Hingga Mei 2017, Wikipedia Bahasa Indonesia telah memuat lebih dari 400.000 artikel dari berbagai domain dan terus berkembang secara pesat. Artikel-artikel yang disimpan dalam Wikipedia dapat diunduh secara gratis dalam bentuk *dumps*¹¹ dengan format XML. Beberapa tipe *dump* yang dapat dipilih, diantaranya adalah halaman seluruh artikel, halaman artikel beserta *revision history*, daftar judul artikel, dan lainnya. Secara berkala, Wikimedia membuat *dump* terhadap seluruh artikel terakhir yang disimpan untuk setiap bahasa. Pada situs yang menyediakan pengunduhan data Wikipedia, terdapat tanggal unik yang menyatakan tanggal terakhir data tersebut di-*update*.

Artikel dalam Wikipedia terdiri dari berbagai domain kategori dan memuat berbagai entitas leksikal. Kata-kata tersebut dapat ditemukan dalam berbagai lek-

¹⁰www.wikipedia.org

¹¹dumps.wikimedia.org

sikal semantik *resource* yang sudah ada. Zesch et al. (2007) melakukan penelitian yang membandingkan data Wikipedia dengan leksikal semantik *resource* yang sudah ada seperti kamus, tesaurus, WordNet, dan ensiklopedia. Istilah-istilah yang ada dalam Wikipedia lebih mirip dengan ensiklopedia dibanding kamus, tesaurus, maupun WordNet karena memuat lebih banyak kata benda (*noun*) dibanding kata sifat (*adjective*) atau kata kerja (*verb*). Selain itu, Wikipedia juga mengandung banyak kata yang merupakan *named entity* atau *domain specific terms*. Penelitian ini berfokus pada kata-kata yang merupakan kata benda, sehingga Wikipedia cocok digunakan.

Walau ditulis secara kolaboratif, Wikipedia memuat artikel secara terstruktur dimana pada paragraf pertama umumnya berisi kalimat-kalimat definisi mengenai topik yang sedang dibahas. Paragraf selanjutnya memuat bahasan yang lebih rinci. Setiap artikel ditulis dalam bahasa yang formal dan terstruktur. Selain itu, sudah banyak penelitian ekstraksi relasi semantik kata berbasis *pattern* yang menggunakan artikel Wikipedia sebagai *resource* seperti penelitian yang dilakukan oleh Ruiz-Casado et al. (2005) dan Arnold dan Rahm (2014). Melihat banyaknya manfaat dan kelebihan Wikipedia, diputuskan untuk menggunakan Wikipedia sebagai leksikal semantik *resource* dalam penelitian ini.

2.2.3 Korpus Pasangan Kata Relasi Semantik

Korpus adalah data yang dengan format yang dapat dibaca oleh mesin dan memiliki fungsi spesifik (Atkins et al., 1992). Saat ini, belum ada korpus independen yang menyimpan relasi semantik antar kata dalam Bahasa Indonesia. Relasi semantik Bahasa Indonesia yang ada saat ini didapatkan dari hasil relasi turunan pemetaan *synset* Bahasa Indonesia dengan WordNet Princeton.

Korpus relasi semantik yang ingin dibuat menyimpan informasi dalam bentuk pasangan kata berelasi serta relasi yang menghubungkannya. Pasangan kata relasi akan disebut sebuah relasi biner dengan format sebagai berikut.

$$hiponim(w_1, w_2)$$

Format di atas dibaca w_1 adalah hiponim dari w_2 atau dapat dikatakan juga bahwa w_2 adalah hipernim dari w_1 . Selanjutnya pasangan kata relasi akan disebut sebagai *pair*. Pada penelitian ini, korpus pasangan kata relasi hipernim-hiponim yang dibentuk tidak memperdulikan jarak hubungan antar kata, sehingga korpus dapat mengandung *pair* ‘hiponim(kelinci, mamalia)’ serta ‘hiponim(kelinci, makhluk hidup)’.

2.3 Relation Extraction

Relation extraction adalah cabang dari *Information Extraction* (IE) yang berfokus pada proses ekstraksi relasi antar kata. Proses ini berusaha mengekstrak informasi terstruktur dengan definisi yang diinginkan dari teks dokumen atau *resource* yang tidak terstruktur. Beberapa contoh penelitian ini seperti *named entity recognition* (NER) yang berusaha mengidentifikasi apakah suatu entitas adalah orang, organisasi, atau lokasi (Bikel et al., 1999).

2.3.1 Semantic Relation Extraction

Semantic relation extraction mengkhususkan pada proses ekstraksi relasi semantik antar kata. Penelitian dalam bidang ini sudah banyak dilakukan dengan berbagai metode. Salah satu metode populer untuk mendapatkan relasi semantik kata adalah menggunakan *pattern extraction* dan *pattern matching* seperti yang telah dilakukan pada penelitian Hearst (1992), Ruiz-Casado et al. (2005), dan Arnold dan Rahm (2014). Penelitian lain memanfaatkan distribusi kata untuk memperoleh *semantic distance* antar kata. *Semantic distance* adalah nilai yang merepresentasikan kedekatan antar kata berdasarkan semantiknya.

Penelitian yang dilakukan oleh Hearst (1992) merupakan salah satu penelitian awal ekstraksi relasi semantik yang menggunakan metode *pattern extraction* dan *matching*. Hearst menggunakan *lexico-syntactic pattern* untuk mendapatkan pasangan kata relasi tanpa membutuhkan pengetahuan sebelumnya dan dapat diaplikasikan dalam teks apapun. Pada awal pengembangan, Hearst mendefinisikan manual dua *pattern* berdasarkan hasil observasi dari teks. Selanjutnya, *pattern* baru didapat menggunakan langkah berikut.

1. Tentukan relasi yang akan diamati dan kumpulkan entitas yang menggambarkan relasi tersebut.
2. Dalam teks dokumen, cari lokasi dimana entitas-entitas tersebut berada dan simpan kata-kata diantaranya (lingkungan).
3. Cari kesamaan dari teks yang terekstraksi dan bentuk suatu *pattern* baru.
4. Jika *pattern* baru telah terbukti benar, gunakan *pattern* tersebut untuk mendapatkan entitas baru.

Proses evaluasi dilakukan dengan membandingkan entitas yang dihasilkan dengan *synset* dalam WordNet.

Penelitian yang dilakukan oleh Ruiz-Casado et al. (2005), memanfaatkan WordNet dan Wikipedia sebagai korpus untuk mendapatkan pasangan kata relasi. Penelitian ini dilakukan untuk mengekstrak kata dengan relasi hipernim-hiponim dan sinonim. Pertama dilakukan *entry sense disambiguation* yang merupakan tahap *pre-processing* untuk memetakan setiap *entry* dalam Wikipedia dengan *synset* dalam WordNet. Tahap berikutnya adalah ekstraksi *pattern* antara dua kata yang bertipe konsep. Jika terdapat dua konsep yang saling berhubungan dan memiliki suatu relasi semantik dalam WordNet maka kalimat yang mengandung dua konsep tersebut akan disimpan. Proses tersebut menghasilkan daftar relasi semantik dengan masing-masing memiliki *pattern* di dalamnya. Dari banyak *pattern* yang dihasilkan, proses selanjutnya adalah *pattern generalisation* yang bertujuan membuat *pattern* yang lebih umum. Tahap ini memanfaatkan algoritma *edit-distance* dengan modifikasi. Setelah mendapatkan *pattern*, tahapan terakhir adalah menggunakannya ke dalam korpus untuk memperoleh entitas baru.

Penelitian yang dilakukan Arnold dan Rahm (2014) juga memanfaatkan korpus Wikipedia dan menggunakan metode berbasis *pattern*. Selain hipernim-hiponim, penelitian ini juga mengidentifikasi relasi meronim-holonim dan sinonim. Kalimat definisi dalam artikel Wikipedia di-*parse* menggunakan *Finite State Machine* (FSM) dan konsep-konsep baru diekstrak menggunakan *pattern* yang telah didefinisikan. Penelitian lain yang dilakukan oleh Sumida dan Torisawa (2008) memanfaatkan struktur hirarki internal Wikipedia dalam mengekstraksi *pattern* relasi untuk Bahasa Jepang.

2.4 Pattern Analysis

Pattern adalah suatu bentuk yang dapat merepresentasikan kumpulan data dengan ukuran besar. Pada teks dokumen, *pattern* dapat terbentuk secara eksplisit ataupun implisit. Secara eksplisit seperti *lexico-syntactic pattern* yang terbentuk dari kata-kata di dalam dokumen tersebut. Sementara *pattern* terbentuk secara implisit jika dilihat dari kemiripan vektor yang merepresentasikan dokumen atau kata-kata di dalam dokumen tersebut.

Lexico-syntactic pattern adalah *pattern* yang hanya memanfaatkan kata-kata dalam korpus dokumen untuk digunakan pada tahap *string matching*. Salah satu *pattern* leksikal yang terkenal adalah Hearst Pattern yang merepresentasikan pola-pola untuk mendapatkan relasi hiponim dari dokumen (Hearst, 1992). Menurut Hearst, beberapa syarat yang harus dipenuhi suatu *lexico-syntactic pattern* yang baik adalah sebagai berikut.

- Kemunculannya sering pada teks dalam berbagai domain sehingga dapat mengekstrak banyak entitas.
- Merepresentasikan relasi yang diinginkan sehingga hasil ekstraksi juga benar.
- Dapat dikenali tanpa membutuhkan pengetahuan sebelumnya sehingga dapat dibentuk dalam situasi apapun.

2.4.1 Textual Pattern

Pattern yang akan dibentuk adalah *pattern* tekstual yang hanya terdiri dari kata-kata. Sebuah *pattern* mengandung tiga bagian penting, yaitu *tag* hiponim, *tag* hipernim, dan kata lainnya. *Tag* hiponim-hipernim merepresentasikan letak kata yang merupakan kata hiponim-hipernim berada. Sementara kata lainnya adalah kata-kata yang harus sama saat dibandingkan dalam proses *pattern matching*. Sebagai contoh terdapat tekstual *pattern* berikut ‘<hyponym> adalah <hypernym> yang’. *Pattern* tersebut berarti kata sebelum kata ‘adalah’ merupakan kata hiponim dan kata setelah kata ‘adalah’ dan sebelum kata ‘yang’ merupakan kata hipernim. Jika terdapat kalimat ‘harimau adalah kucing yang berukuran besar’, maka ‘harimau’ merupakan hiponim dan ‘kucing’ merupakan hipernim. Di dalam kata lainnya, terdapat *tag* khusus yang digunakan dalam penelitian ini yaitu <start> dan <end>. Kedua *tag* tersebut membantu mengetahui kata-kata yang terletak pada awal dan akhir kalimat.

2.4.2 Pattern Extraction

Pattern extraction atau *pattern recognition* adalah salah satu cabang dalam *machine learning* yang berusaha mencari pola kemiripan tertentu dari kumpulan data yang diberikan. *Pattern* yang akan dibentuk adalah *textual pattern*, sehingga proses pembentukan *pattern* dilakukan dengan cara mencari kemiripan diantara kumpulan kalimat yang jumlahnya banyak. Penelitian ini memanfaatkan struktur data *tree* dalam pembentukan *pattern* yang secara detil dapat dilihat pada bab 2.5.1. Suatu kalimat ditokenisasi dan *sequence* kata yang dihasilkan membentuk *path* dalam *tree*. *Node* dalam *tree* merepresentasikan satu kata dalam kalimat. *Sequence* kata yang sering muncul menjadi *pattern* terbaik untuk kumpulan dokumen yang sedang diamati.

2.4.3 Pattern Matching

Pattern matching adalah proses untuk mencocokkan suatu *pattern* terhadap kumpulan data yang belum dianotasi. Jika diberikan sebuah *pattern* tekstual, proses ini akan mencocokkan *sequence* kata dalam *pattern* terhadap *sequence* kata dalam kalimat yang diamati. Jika terdapat satu token dalam *sequence pattern* yang tidak sama dengan *sequence* kalimat, maka proses pencarian dapat dikatakan gagal. Sementara, jika terdapat *sequence* kata dalam kalimat yang sama dengan *sequence* kata dalam *pattern*, maka dianggap berhasil dan akan menghasilkan sebuah *pair* baru. Penelitian ini memanfaatkan representasi *suffix tree* untuk mempermudah proses pencarian. Lebih detail mengenai proses pembentukan *suffix tree* dan pencocokan *pattern*, dapat dilihat pada bab 2.5.2.

2.5 Tree Representation

Dalam penelitian ini, segala hal yang berkaitan dengan proses pembuatan *pattern* (*pattern extraction*) maupun ekstraksi *pair* baru (*pattern matching*), memanfaatkan struktur data *tree*. Struktur data tersebut mempermudah proses pembentukan maupun pencarian *pattern* tekstual karena setiap kata dapat direpresentasikan sebagai *node*. Pencocokan *sequence* kata dapat dengan mudah dilakukan dengan menelusuri *path* dari *root node* dalam *tree*. Dua tipe *tree* yang menjadi fokus penelitian adalah *standard tree* dan *suffix tree*.

2.5.1 Standard Tree

Standard Tree adalah bentuk paling dasar suatu *tree*. *Tree* ini akan membentuk *path* untuk setiap *sequence string* yang menjadi masukan. *Standard Tree* untuk suatu himpunan *string S* adalah *ordered tree* dengan ketentuan berikut.

- Setiap *node*, selain *root*, diberi label sebuah *character*
- *Children* dari sebuah *node* terurut sesuai alphabet
- *Path* dari eksternal *node* hingga *root* membentuk suatu *string* dalam *S*.

Standard Tree membutuhkan memori sebesar $O(n)$ dimana n adalah total ukuran *string* dalam *S*. Operasi *insert* butuh waktu $O(dm)$ dimana m adalah ukuran *string* yang baru dan d adalah ukuran alphabet. Sebagai contoh berikut adalah *standard tree* yang dibangun dari himpunan *string* $S = \{ \text{'apel'}, \text{'ayam'}, \text{'baju'}, \text{'baja'}, \text{'bara'} \}$.

Dari contoh di atas, proses pencarian dapat dijalankan dengan cepat karena seluruh *suffix* telah didaftarkan ke dalam *tree*. Dari *query* yang ingin dicari, dapat langsung dicocokkan setiap karakternya.

2.6 Semi-Supervised

Dalam *machine learning* terdapat dua tipe pendekatan yang umum digunakan yaitu *supervised* dan *unsupervised learning*. *Supervised* menggunakan data berlabel sebagai data *training* maupun *testing*. Dari kedua data tersebut, dibentuk suatu *classifier* yang dapat memenuhi segala kasus yang mungkin terjadi. Data *testing* digunakan untuk menguji kebaikan *classifier* yang terbentuk. *Unsupervised* menggunakan data yang tidak diberi label sama sekali dan berusaha untuk menemukan pola yang sama untuk suatu kumpulan data tertentu (Prakash dan Nithya, 2014). Pendekatan lain yang merupakan kombinasi antara *supervised* dan *unsupervised learning* adalah *semi-supervised learning*.

Semi-supervised adalah pendekatan *machine learning* dimana informasi *supervised* data diberikan tidak untuk seluruh data. Sebagian data merupakan data berlabel sementara sebagian lainnya belum memiliki label. Beberapa metode penerapan *semi-supervised* adalah *bootstrapping* (*self training*), *mixture models*, *graph based methods*, *co-training*, dan *multiview learning*.

2.6.1 Bootstrapping

Model *bootstrapping* merupakan salah satu model *semi-supervised learning* yang paling umum digunakan. *Bootstrapping* menggunakan data berlabel berukuran kecil dan data tidak berlabel berukuran jauh lebih besar. Proses anotasi data tidak berlabel dilakukan secara bertahap melalui sejumlah iterasi. Dari data *training* berlabel, dibentuk suatu *classifier* yang kemudian digunakan untuk menganotasi data tidak berlabel. Sejumlah k data baru yang merupakan hasil pelabelan tersebut, dimasukkan ke dalam kelompok data berlabel. Proses tersebut dilakukan secara berulang, sehingga semakin lama iterasi jumlah data berlabel akan bertambah.

Terdapat dua algoritma *bootstrapping* yang pernah digunakan untuk proses berbasis *pattern* yaitu *Meta-Bootstrapping* dan *Basilisk* (Riloff et al., 2003). Keduanya digunakan untuk mengelompokkan kata ke dalam suatu kategori semantik jika diberikan korpus teks yang belum dianotasi dan sejumlah *seed*. *Seed* didefinisikan sebagai korpus kata yang sudah diketahui kategori semantiknya. Secara umum, proses ini akan mencari *pattern* berdasarkan *seed* yang diberikan. Dari *pattern* yang dihasilkan dan teks yang belum dianotasi, diekstrak entitas baru dan dikelompokkan

berdasarkan kategori semantiknya. Kata-kata tersebut akan digabungkan ke dalam korpus pasangan kata berelasi.

2.6.2 Meta-Bootstrapping

Meta-Bootstrapping adalah salah satu variasi dari *bootstrapping* yang memanfaatkan *pattern* dalam *cycle semi-supervised*-nya. Berikut adalah beberapa proses (Riloff et al., 1999) yang dijalankan algoritma ini jika diberikan *seed* berukuran kecil yang berasal dari suatu kategori semantik dan korpus yang belum dianotasi.

1. Mengekstraksi *pattern* secara otomatis dengan menerapkan *syntactic template*.
2. *Pattern* diberi bobot berdasarkan jumlah *seed* yang membentuknya.
3. Diambil *pattern* terbaik dan seluruh *seed* lama yang membangun *pattern* maupun *seed* baru yang berhasil diekstrak oleh *pattern* tersebut.
4. Dilakukan pembobotan ulang untuk setiap *pattern* menggunakan *seed* lama dan baru.

Proses diatas dinamakan *mutual bootstrapping* dan setelah proses tersebut selesai, semua entitas baru hasil ekstraksi dievaluasi. Pembobotan entitas baru diberikan berdasarkan jumlah *pattern* yang mengekstrak kata tersebut. Lima kata terbaik diterima dan dimasukkan ke kamus (korpus) kata berelasi untuk selanjutnya diproses ulang.

2.6.3 Basilisk

Mirip seperti *Meta-Bootstrapping*, algoritma *Basilisk* (Thelen dan Riloff, 2002) juga memanfaatkan *pattern* dan *seed* dalam membangun korpus untuk suatu kategori semantik tertentu. Beberapa tahapan yang dijalankan adalah sebagai berikut.

1. Secara otomatis membentuk *pattern* dan memberi bobot berdasarkan jumlah *seed* yang menghasilkan *pattern*. *Pattern* terbaik dimasukan ke dalam *Pattern Pool*.
2. Untuk setiap entitas baru yang terekstraksi dari *pattern*, dimasukan ke dalam *Candidate Word Pool*. Pemberian bobot dilakukan berdasarkan jumlah *pattern* yang mengekstraksi dan asosiasi kumulatif kata dengan *seed*.

3. Sepuluh kata terbaik diambil dan dimasukkan ke dalam kamus (korpus) yang kemudian digunakan untuk iterasi selanjutnya.

Kategori semantik untuk proses ini bisa lebih dari satu. *Basilisk* memberi bobot berdasarkan informasi kolektif dari kumpulan *pattern* yang mengekstrak kata tersebut. Sementara *Meta-Bootstrapping* hanya mengambil satu *pattern* terbaik dan mengelompokkan seluruh kata yang terekstrak dari *pattern* ke dalam kategori semantik yang sama. Dari hasil penelitian komparatif yang pernah dilakukan (Riloff et al., 2003), didapatkan *Basilisk* mengungguli performa *Meta-Bootstrapping*.

2.7 Evaluasi

Evaluasi dilakukan untuk mengetahui kebaikan hasil penelitian. Evaluasi dapat dilakukan dengan mengukur akurasi data yang dihasilkan. Akurasi adalah nilai perbandingan antara jumlah data yang benar dengan jumlah seluruh data (Manning et al., 2008).

$$akurasi = \frac{jumlah\ data\ benar}{jumlah\ seluruh\ data} \quad (2.1)$$

Selain menghitung akurasi, proses evaluasi juga menghitung nilai-nilai lainnya. Berikut ada beberapa metode dan teknik evaluasi lain yang digunakan dalam penelitian.

2.7.1 Sampling

Terdapat dua kategori utama dalam *sampling* yaitu *probability* dan *non-probability sampling*. Perbedaan utama keduanya adalah pada *probability sampling*, diambil data secara acak (*random*). Dalam *probability sampling*, terdapat beberapa metode yang dapat digunakan seperti *simple random sampling*, *systematic sampling*, *stratified random sampling*, dan *cluster sampling*.

- *Simple random sampling* perlu mengetahui seluruh data yang ada dan dari data tersebut dipilih secara acak. Hal ini membuat seluruh data memiliki nilai probabilitas terpilih yang sama.
- *Systematic sampling* memilih setiap data ke-n untuk dijadikan *sample*.
- *Stratified random sampling* akan mengelompokkan data ke dalam kategori berdasarkan karakteristik tertentu (*strata*), kemudian data diambil secara acak dari kategori yang ada. Hal ini menyebabkan hasil lebih representatif.

- *Cluster sampling* mirip seperti *stratified sampling* namun dilakukan jika data kelompok yang ingin di-*sampling* sulit berada di lokasi yang terpisah jauh.

Proses *sampling* bermanfaat untuk merepresentasikan data tanpa perlu mengevaluasi seluruh data yang ada. Jika jumlah data yang ingin dievaluasi berukuran besar, proses *sampling* mempercepat pengukuran. Jumlah data yang direpresentasikan oleh satu sample berdasarkan jumlah data asli. Sebagai contoh jika total data adalah 1000 dan jumlah data sample adalah 50, maka satu data *sample* merepresentasikan 20 data asli.

2.7.2 Precision dan Recall

Teknik yang umum digunakan untuk mengevaluasi suatu ekstraksi adalah *precision* dan *recall*. *Precision* adalah nilai yang menyatakan jumlah dokumen benar dan berhasil diambil dibandingkan dengan seluruh jumlah dokumen yang diambil. *Recall* adalah nilai yang menyatakan jumlah dokumen benar dan berhasil diambil dibandingkan dengan jumlah seluruh dokumen yang benar. Semakin banyak dokumen yang diambil maka nilai *recall* akan meningkat sementara nilai *precision* cenderung menurun.

2.7.3 Kappa

Nilai kappa (κ) merepresentasikan tingkat persetujuan antar anotator. Kappa digunakan pada penelitian yang menggunakan bantuan anotator untuk memberi penilaian secara manual. Penilaian didapatkan menggunakan rumus 2.2.

$$\kappa = \frac{P(A) - P(E)}{1 - P(E)} \quad (2.2)$$

- $P(A)$ adalah proporsi penilaian yang setuju (*agreement*)
- $P(E)$ adalah proporsi penilaian yang kebetulan

Landis dan Koch (1977) mendefinisikan tingkat persetujuan berdasarkan nilai Kappa yang diperoleh.

Tabel 2.1: Skala pengukuran Kappa

Statistik Kappa	Tingkat persetujuan
< 0.00	<i>Poor</i>
0.00 - 0.20	<i>Slight</i>
0.21 - 0.40	<i>Fair</i>
0.41 - 0.60	<i>Moderate</i>
0.61 - 0.80	<i>Substantial</i>
0.81 - 1.00	<i>Almost Perfect</i>

Beberapa variasi perhitungan untuk Kappa adalah Cohen's Kappa dan Fleiss' Kappa. Cohen's Kappa digunakan untuk mengukur tingkat persetujuan antar dua anotator. Jika diberikan data dengan n label dan m_{ij} merepresentasikan jumlah data yang diberi label i oleh anotator pertama dan label j oleh anotator kedua, maka proses perhitungan $P(A)$ dan $P(E)$ untuk Cohen's Kappa adalah sebagai berikut.

$$P(A) = \frac{\sum_{k=1}^n m_k k}{\text{total data}}$$

$$P(E) = \frac{\sum_{k=1}^n (\sum_{j=1}^n m_{kj} \cdot \sum_{i=1}^n m_{ik})}{\text{total data}}$$

Fleiss' Kappa mengukur tingkat persetujuan antar sekelompok anotator berjumlah lebih dari dua. Jika diberikan N data dengan n anotator dimana setiap data diantosi ke dalam salah satu dari k kategori dan n_{ij} merepresentasikan total anotator yang memberi data i ke label j , proses perhitungan $P(A)$ dan $P(E)$ untuk Fleiss' Kappa adalah sebagai berikut.

$$P(A) = \frac{1}{N} \sum_{i=1}^N P_i \text{ dengan } P_i = \frac{1}{n(n-1)} [(\sum_{j=1}^k n_{ij}^2 j) - (n)]$$

2.7.4 Spearman's Rho

Spearman's rank correlation coefficient adalah nilai koefisien korelasi antar *ranking* dua parameter. Nilai *Spearman correlation* sama dengan nilai *Pearson correlation* antar dua parameter yang telah di-*ranking*. *Pearson correlation* menggambarkan nilai linear antara dua parameter. *Spearman correlation* berkisar antara -1 hingga $+1$.

Spearman's rho adalah nilai Pearson Correlation Coefficient antar dua variabel yang telah di-*ranking*. Untuk mendapatkan nilai koefisien (r_s), menggunakan rumus

berikut.

$$r_s = \rho_{rg_X, rg_Y} = \frac{cov(rg_X, rg_Y)}{\sigma_{rg_X} \sigma_{rg_Y}} \quad (2.3)$$

- ρ adalah *Pearson correlation coefficient* yang diaplikasikan pada variabel *ranking*
- $cov(rg_X, rg_Y)$ adalah nilai *covariance* antar variabel *ranking*
- σ_{rg_X} dan σ_{rg_Y} adalah nilai standard deviasi variabel *ranking*

Jika seluruh *ranking* berbeda, proses komputasi dapat dilakukan menggunakan rumus berikut.

$$r_s = 1 - \frac{6\sum d_i^2}{n(n^2 - 1)} \quad (2.4)$$

- $d_i = rg(X_i) - rg(Y_i)$ adalah selisih antara dua *ranking*
- n adalah jumlah observasi


BAB 3

RANCANGAN METODOLOGI

Pada bab ini dipaparkan mengenai rancangan dan tahap-tahap proses ekstraksi relasi semantik, mulai dari rancangan pengembangan korpus, pembentukan *seed*, pembentukan *pattern*, ekstraksi *pair*, *cycle semi-supervised*, dan strategi evaluasi yang dilakukan untuk pasangan kata relasi Bahasa Indonesia.

3.1 Rancangan Pengembangan Korpus

Penelitian ini mengusulkan pengembangan korpus pasangan kata berelasi menggunakan arsitektur yang dapat dilihat pada gambar 3.1. Terdapat dua sumber data utama yang digunakan yaitu WordNet Bahasa untuk pembentukan *seed* dan artikel Wikipedia Bahasa Indonesia sebagai korpus teks. Secara garis besar, terdapat beberapa tahap yang perlu dilakukan yaitu pembuatan *seed*, *pre-processing* data Wikipedia, *sentence tagging*, *pattern extraction*, *pattern matching*, dan terakhir adalah evaluasi. Untuk proses *sentence tagging*, *pattern extraction*, dan *pattern matching* dilakukan secara berulang sesuai dengan metode *bootstrapping*.



Gambar 3.1: Arsitektur Penelitian

Berikut adalah penjelasan singkat setiap tahapan pada gambar di atas.

1. *Pre-processing data*

Sebelum memulai penelitian, terdapat dua hal utama yang perlu dilakukan yaitu pengumpulan *seed* dan pembentukan kalimat Wikipedia. Pengumpulan *seed* dilakukan untuk mendapatkan pasangan kata relasi yang digunakan sebagai dasar penelitian. Proses ini memanfaatkan *resource* yang dimiliki WordNet Bahasa. Selanjutnya, artikel Wikipedia yang diperoleh dalam bentuk *Wikipedia dump* perlu diolah sehingga memiliki representasi sesuai dengan format yang diharapkan. Informasi yang diperlukan hanya bagian isi artikel dan ditulis dalam bentuk kalimat untuk setiap baris.

2. Pembentukan *pattern*

Menggunakan *seed* dan korpus kalimat Wikipedia, dilakukan *tagging* pasangan kata berelasi terhadap kalimat-kalimat yang ada. Kalimat yang mengandung pasangan kata berelasi akan ditandai dan disimpan sebagai dasar proses selanjutnya. Kalimat-kalimat yang sudah di-*tag* dengan pasangan kata berelasi kemudian akan digunakan untuk proses *pattern extraction*. Hasil dari proses ini adalah sejumlah *pattern* leksikal terbaik dari banyak *pattern* unik yang dihasilkan.

3. Ekstraksi pasangan kata relasi

Pattern yang dihasilkan digunakan untuk mengekstrak pasangan kata relasi baru dengan dibantu korpus Wikipedia dengan *POS tag*. Proses *pattern matching* dilakukan dengan mencocokkan kata-kata bebas dalam *pattern* dengan kalimat, kemudian mengambil bagian yang menempati posisi *tag* hipernim-hiponim. Pasangan kata yang dihasilkan masuk ke dalam korpus pasangan kata relasi hipernim-hiponim.

4. *Cycle semi-supervised*

Korpus pasangan kata relasi yang terbentuk digunakan untuk iterasi selanjutnya sesuai dengan metode *bootstrapping*. Proses iterasi dilakukan hingga jumlah pasangan kata relasi baru yang dihasilkan jenuh. Setelah satu eksperimen selesai, proses evaluasi dilakukan secara kolektif untuk mengetahui akurasi setiap data yang dihasilkan.

Proses ini diharapkan dapat menghasilkan korpus pasangan kata relasi *hyponym-hypernym* yang berkualitas baik dan berukuran besar.

3.2 Pre-processing Data

Proses inti dari penelitian ini, *pattern extraction* dan *matching*, memerlukan dua masukan utama yaitu sejumlah pasangan kata hipernim-hiponim (*seed*) dan teks dokumen yang digunakan sebagai korpus. Pasangan kata hipernim-hiponim digunakan untuk proses pembentukan *pattern* sementara teks dokumen digunakan untuk memperoleh pasangan kata baru. Dikarenakan belum ada korpus pasangan kata relasi hipernim-hiponim Bahasa Indonesia, perlu dibentuk *seed* yang akan digunakan sebagai dasar pasangan kata hipernim-hiponim. Teks dokumen yang digunakan, yaitu Wikipedia, juga memerlukan pemrosesan sebelum menjadi masukan sistem.

3.2.1 Pembentukan Kalimat Wikipedia

Data Wikipedia yang diperoleh dari Wikimedia *dumps* masih mengandung banyak *tag* yang tidak digunakan pada penelitian ini seperti *tag id* dan *revision*. Selain itu simbol-simbol khusus (*markup*). Penelitian ini ingin mengekstrak *pattern* dari *free text*, sehingga format-format khusus tersebut perlu dibersihkan. Gambar 3.2 menunjukkan contoh data XML yang diperoleh dari Wikimedia Dump. Setelah data Wikipedia dibersihkan dari simbol-simbol tersebut, langkah selanjutnya adalah merepresentasikan korpus dalam bentuk kalimat.

```
<page>
  <title>Asam deoksiribonukleat</title>
  <ns>0</ns>
  <id>1</id>
  <revision>
    <id>12184290</id>
    <parentid>12009030</parentid>
    <timestamp>2017-01-23T04:32:50Z</timestamp>
    <contributor>
      <username>HsfBot</username>
      <id>820984</id>
    </contributor>
    <minor />
    <comment>Bot: Perubahan kosmetika</comment>
    <model>wikitext</model>
    <format>text/x-wiki</format>
    <text xml:space="preserve">[[Berkas:DNA Structure+Key+Labelled.pn NoBB.png|thumb|right|340px|Struktur [[heliks ganda]] DNA. [[Atom]]-atom pada struktur tersebut diwarnai sesuai dengan [[unsur kimia]]nya dan struktur detail dua pasangan basa ditunjukkan oleh gambar kanan bawah]]
[[Berkas:ADN animation.gif|thumb|Gambaran tiga dimensi DNA]]
'''Asam deoksiribonukleat''', lebih dikenal dengan singkatan '''DNA''' ([[bahasa Inggris]]: '''d''''eoxyribo''''n''''ucleic '''a''''cid'''), adalah sejenis biomolekul yang menyimpan dan menyandi instruksi-instruksi [[genetika]] setiap [[organisme]] dan banyak jenis [[virus]]. Instruksi-instruksi genetika ini berperan penting
```

Gambar 3.2: Data XML Wikipedia Dump

Artikel-artikel Wikipedia dibentuk ke dalam format yang telah didefinisikan de-

ngan satu kalimat dipisahkan untuk setiap barisnya. Selanjutnya, data akan di format ulang sesuai definisi untuk mempermudah pemrosesan selanjutnya. Beberapa aturan yang diberikan adalah menghilangkan frasa di dalam tanda kurung, menghilangkan simbol, serta memberi *tag start* dan *end* pada awal dan akhir kalimat.

```
<start> Asam deoksiribonukleat , lebih dikenal dengan singkatan DNA , adalah sejenis biomolekul yang menyimpan dan menyandi instruksi-instruksi genetika setiap organisme dan banyak jenis virus . <end>
<start> Instruksi-instruksi genetika ini berperan penting dalam pertumbuhan , perkembangan , dan fungsi organisme dan virus . <end>
<start> DNA merupakan asam nukleat ; bersamaan dengan protein dan karbohidrat , asam nukleat adalah makromolekul esensial bagi seluruh makhluk hidup yang diketahui . <end>
```

Gambar 3.3: Korpus kalimat Wikipedia tanpa *POS tag*

```
<start> X Asam NNP deoksiribonukleat NNP , Z lebih RB dikenal VB dengan IN singkatan NN DNA FW , Z adalah VB sejenis NND biomolekul NN yang SC menyimpan VB dan CC menyandi VB instruksi-instruksi NN genetika NN setiap CD organisme NN dan CC banyak CD jenis NND virus NN . Z <end> X
<start> X Instruksi-instruksi NN genetika NN ini PR berperan VB penting JJ dalam IN pertumbuhan NN , Z perkembangan NN , Z dan CC fungsi NN organisme NN dan CC virus NN . Z <end> X
<start> X DNA FW merupakan VB asam NN nukleat NN ; Z bersamaan VB dengan IN protein NN dan CC karbohidrat NN , Z asam NNP nukleat NNP adalah VB makromolekul NN esensial NN bagi IN seluruh CD makhluk NN hidup NN yang SC diketahui VB . Z <end> X
```

Gambar 3.4: Korpus kalimat Wikipedia *POS tag*

Korpus kalimat yang dihasilkan kemudian digunakan untuk proses *part-of-speech tagging*. Hasil dari *pre-processing* data Wikipedia adalah dua korpus besar yaitu korpus kalimat tanpa *POS tag* (Gambar 3.3) yang digunakan sebagai masukan *pattern extraction* dan korpus kalimat dengan *POS tag* (Gambar 3.4) yang digunakan sebagai masukan *pattern matching*.

3.2.2 Pengumpulan Seed

Pasangan kata relasi hipernim-hiponim diambil dari data yang dimiliki oleh WordNet Bahasa yang dikembangkan oleh NTU. Pemanfaatan WordNet Bahasa dilatarbelakangi jumlahnya yang lebih besar dibanding Indonesian WordNet (IWN). Relasi semantik antar kata pada WordNet Bahasa memanfaatkan WordNet Princeton versi 3.0. *Synset* pada WordNet Bahasa dipetakan ke *synset* WordNet Princeton, sehingga relasi semantik yang dimiliki oleh WordNet Princeton ikut diwarisi. Alasan lain penggunaan WordNet Bahasa adalah karena telah terintegrasi dengan *tools* nltk sehingga dapat langsung digunakan untuk membentuk *seed* secara mudah.

Seluruh lema Bahasa Indonesia yang ada di dalam korpus WordNet Bahasa diambil. Untuk setiap lema, akan dicari hipernimnya sehingga dapat dibentuk men-

jadi pasangan kata relasi hipernim-hiponim. Sayangnya, tidak semua pasangan kata yang dihasilkan adalah benar akibat beberapa kekurangan yang dimiliki WordNet Bahasa. Untuk itu dilakukan proses filterisasi untuk meminimalisir *error* yang mungkin terjadi. Dua tipe filterisasi yang digunakan adalah filterisasi lema sama dan filterisasi *strict*. Filterisasi lema sama memperbolehkan pasangan kata terbentuk dari kata dengan *synset* hiperim berbenda namun memiliki sejumlah lema yang sama. Sementara filterisasi *strict* tidak memperbolehkan hal tersebut. Seluruh pasangan kata yang lolos proses filterisasi dibentuk menjadi *tuple* biner. Hasil akhir dari proses ini adalah himpunan *tuple* yang berisi dua elemen dengan format $(w_1; w_2)$ dimana w_1 pertama merupakan kata hiponim dan w_2 merupakan kata hipernimnya.

Beberapa contoh *seed* yang dihasilkan adalah ‘(novel;buku)’, ‘(salmon;ikan)’, ‘(humus;tanah)’, ‘(oktan;ukuran)’, dan ‘(kucai;sayuran)’.

3.3 Pembentukan Pattern

Pattern leksikal yang akan digunakan ingin seluruhnya dibentuk secara otomatis oleh sistem. Terdapat dua masukan utama untuk proses ini yaitu pasangan kata relasi hipernim-hiponim yang telah diketahui dan korpus dokumen. Pada tahap awal, pasangan kata relasi masukan adalah *seed* yang dibentuk menggunakan WordNet Bahasa. Untuk tahap selanjutnya, pasangan kata relasi menggunakan korpus *pair* hasil proses ekstraksi. Terdapat dua tahapan utama dalam pembentukan *pattern* yaitu *sentence tagging* dan *pattern extraction*.

3.3.1 Sentence Tagging

Sentence tagging adalah proses *intermediate* yang perlu dilakukan sebelum sistem dapat membentuk sebuah *pattern* leksikal. Proses ini akan memberi *tag* hipernim dan hiponim terhadap suatu kata di dalam kalimat. Masukan untuk proses ini adalah pasangan kata relasi dan korpus Wikipedia tanpa *POS tag*. Untuk setiap kalimat dalam korpus Wikipedia, dicek apakah kalimat tersebut mengandung pasangan kata relasi. Jika mengandung, maka kata dalam kalimat yang merupakan pasangan kata akan di-*tag* hipernim dan hiponim. Satu kalimat dicocokkan dengan seluruh pasangan kata relasi karena terdapat kasus dimana satu kalimat mengandung lebih dari satu pasangan kata relasi. Proses ini menghasilkan kalimat-kalimat Wikipedia yang telah diberi *tag* hipernim atau hiponim.

Sebagai contoh, terdapat pasangan kata ‘(sepak bola;olahraga)’ serta kalimat ‘<start> sepak bola adalah cabang olahraga yang menggunakan bola

yang umumnya terbuat dari bahan kulit dan dimainkan oleh dua tim . <end>’. Kalimat dengan tag hipernim-hiponim yang dihasilkan adalah ‘<start> <hyponym>sepak bola<hyponym> adalah cabang <hypernym>olahraga<hypernym> yang menggunakan bola yang umumnya terbuat dari bahan kulit dan dimainkan oleh dua tim . <end>’. Dengan adanya penanda kata mana yang merupakan hipernim dan hiponim, proses ekstraksi *pattern* akan lebih mudah dilaksanakan.

3.3.2 Pattern Extraction

Setelah didapatkan kumpulan kalimat yang sudah diberi *tag* hipernim dan hiponim, dicari barisan kata yang mirip dan dapat dijadikan sebuah *pattern*. *Pattern extraction* adalah proses untuk mendapatkan *pattern* leksikal yang kemunculannya sering dalam korpus. Masukan dari proses ini adalah kalimat-kalimat Wikipedia yang telah diberi *tag* hipernim dan hiponim. Tidak seluruh kata dalam kalimat digunakan untuk membentuk *pattern* leksikal. Bagian dalam kalimat yang diperhatikan adalah kata diantara dua *tag* hipernim-hiponim, n kata sebelum *tag* pertama, dan n kata setelah *tag* terakhir. Bagian kata yang diambil akan dimasukkan ke dalam *pattern tree* untuk mengetahui kemunculannya yang paling sering. Seluruh *pattern* direpresentasikan menjadi vektor dan dirutkan berdasarkan bobot tertinggi. Proses ini akan menghasilkan kumpulan *pattern* unik yang terurut berdasarkan bobotnya. Dari *pattern* unik tersebut, akan diambil sejumlah *pattern* terbaik untuk kemudian digunakan sebagai dasar pembentukan *pair* baru.

Sebagai contoh, proses *sentence tagging* menghasilkan tiga kalimat yang telah diberi *tag* hipernim-hiponim. Kalimat berikut digunakan untuk mencari *pattern* yang merepresentasikan relasi hipernim-hiponim.

- <start> <hyponym>kelinci<hyponym> adalah <hypernym>binatang<hypernym> yang gemar memakan wortel . <end>
- <start> <hyponym>mobil<hyponym> adalah <hypernym>kendaraan<hypernym> beroda empat . <end>
- <start> selain sepak bola, <hyponym>basket<hyponym> adalah <hypernym>olahraga<hypernym> yang disukai masyarakat . <end>

Dari kalimat di atas *pattern* unik yang dihasilkan yaitu ‘<hyponym> adalah <hypernym>’. Lebih detil mengenai bagaimana *pattern* tersebut terbentuk dapat dilihat pada bab 4.4.

3.4 Ekstraksi Pair

Tujuan utama dari penelitian ini adalah membentuk korpus pasangan kata relasi, sehingga proses ekstraksi *pair* adalah tahapan utama dari keseluruhan penelitian. Pada proses ini, dimanfaatkan *pattern* yang telah terbentuk sebelumnya untuk mengekstrak pasangan kata baru. Pasangan kata tersebut kemudian difilter sebelum digabung ke dalam korpus pasangan kata relasi. Ekstraksi *pair* menggunakan teknik *pattern matching*. Selanjutnya *pair* akan diberi bobot dan hanya *pair* yang bobotnya memenuhi nilai *threshold*-lah yang akan dimasukkan dalam korpus pasangan kata relasi.

3.4.1 Pattern Matching

Pattern matching adalah proses mencocokkan suatu *pattern* ke dalam teks dokumen. Proses ini dilaksanakan untuk mendapatkan pasangan kata relasi (*pair*) baru. Dua masukan utama untuk proses ini adalah *pattern* dan korpus Wikipedia *POS tag*. Penggunaan korpus Wikipedia dengan *POS tag* untuk membatasi *pair* yang terekestrak hanya berasal dari kelas kata *noun* atau *proper noun*. Namun, tidak seluruh *pair* yang dihasilkan benar memiliki relasi hipernim-hiponim. Untuk itu, dihitung nilai bobot untuk seluruh *pair* yang dihasilkan. Nilai bobot digunakan untuk dibandingkan dengan nilai *threshold* yang didefinisikan. Hanya *pair* yang bobotnya melebihi nilai *threshold* yang dapat masuk ke korpus pasangan kata relasi.

Sebagai contoh, terdapat *pattern* leksikal ‘<hyponym> adalah <hypernym> yang’. Berikut adalah beberapa kalimat Wikipedia dengan *POS tag*.

- <start>_X sepak_NNP bola_NNP adalah_VB olahraga_NN paling_RB populer_JJ di_IN Britania_NNP ._Z <end>_X
- <start>_X Berikut_VB adalah_VB daftar_NN penghargaan_NN yang_SC diberikan_VB ._Z <end>_X
- <start>_X Gado-gado_NNP adalah_VB makanan_NN yang_SC berasal_VB dari_IN Betawi_NN ._Z <end>_X

Pair yang dihasilkan setelah melalui tahap *pattern matching* hanya ‘(gado-gado;makanan)’. Pasangan kata ‘(berikut;daftar penghargaan)’ tidak termasuk karena kata ‘berikut’ bukan merupakan kata benda (*noun*). Sementara walau ‘(sepak bola;olahraga)’ adalah pasangan kata hipernim-hiponim yang benar, kalimat tersebut tidak cocok dengan *pattern* leksikal yang diberikan menyebabkan *pair*

tidak terekstrak. Lebih rinci mengenai proses ekstraksi *pair* dapat dilihat pada bab 4.5.

3.4.2 Pembobotan dan Filterisasi

Kumpulan *pair* yang berhasil terekstrak tidak seluruhnya diterima ke dalam korpus pasangan kata relasi. Hanya *pair* yang diyakini benar yang dapat masuk, untuk itu perlu dilakukan proses filterisasi. Setiap *pair* akan diberi bobot dimana nilai bobot suatu *pair* dihitung berdasarkan fitur-fitur yang dimiliki yang disimpan dalam bentuk vektor. Informasi utama dalam menghitung bobot suatu *pair* adalah jumlah *pattern* yang membentuk *pair* tersebut serta nilai *similarity* antara dua kata dalam *pair*. Perhitungan jumlah *pattern* pembentuk *pair* dilakukan pada tahap *pattern matching*. Sementara nilai *similarity* dihitung menggunakan model *word embedding*. Setiap *pair* yang nilai bobotnya melebihi nilai *threshold* yang didefinisikan dapat masuk ke dalam korpus pasangan kata relasi.

3.5 Cycle Semi-Supervised

Pembelajaran menggunakan pendekatan *semi supervised learning* dilatarbelakangi ketersediaan pasangan kata relasi semantik yang telah diketahui (*seed*) berukuran terbatas dan korpus berukuran besar yang belum dianotasi. Ingin didapatkan *pair* baru dari korpus yang belum dianotasi tersebut. Metode *semi supervised* yang diterapkan adalah *Bootstrapping*. Untuk lebih spesifiknya, algoritma *bootstrapping* yang digunakan gabungan antara Meta-Bootstrapping dan Basilisk dengan beberapa modifikasi. Pemilihan metode tersebut didasari proses ekstraksi *pair* baru yang memanfaatkan *pattern*. Secara umum, proses *bootstrapping* dikelompokkan ke dalam dua tahap yaitu iterasi pertama dan iterasi ke-2 hingga n .

Pada iterasi pertama, proses pembentukan *pattern* memanfaatkan *seed* yang berasal dari WordNet Bahasa. Tahap *pre-processing* menghasilkan kumpulan *seed* dan korpus kalimat Wikipedia. *Seed* digunakan untuk *tagging* kalimat Wikipedia sehingga menghasilkan kalimat yang telah di-tag hipernim-hiponim. Kalimat-kalimat tersebut digunakan untuk membentuk *pattern* unik yang digunakan untuk memulai iterasi *semi supervised*. *Pattern* yang dibentuk dari filterisasi *seed* lema sama maupun *strict* digabung dan diurutkan berdasarkan bobot yang dimiliki. Lima *pattern* terbaik diambil untuk selanjutnya digunakan dalam proses ekstraksi *pair*. Sementara *seed* yang membentuk kelima *pattern* tersebut langsung dimasukkan ke dalam korpus pasangan relasi kata. Hal tersebut dilakukan untuk memfilter *seed* salah yang terbentuk akibat *error* dari *resource* WordNet Bahasa. Selanjutnya, *pat-*

tern digunakan untuk mengekstrak *pair* baru dan melakukan pembobotan terhadap *pair*. Seluruh *pair* yang nilai bobotnya melebihi *threshold* bergabung dengan *pair* dalam korpus pasangan kata relasi.

Iterasi selanjutnya mirip seperti iterasi pertama yaitu melakukan *tagging* pasangan kata relasi terhadap korpus kalimat Wikipedia. Namun, untuk iterasi ke-2 hingga selanjutnya, pasangan kata yang digunakan untuk proses *tagging* adalah dari korpus pasangan kata relasi semantik yang dihasilkan. Setelah mendapatkan kalimat yang telah di-tag hipernim-hiponim, dilanjutkan dengan proses *pattern extraction*. *Pattern* yang dihasilkan akan digabung dengan seluruh *pattern* lama kemudian diurutkan. Seperti pada metode *Basilisk*, jumlah *pattern* yang digunakan pada iterasi berikutnya akan bertambah. Satu *pattern* terbaik dari hasil pengurutan bergabung dengan *pattern* terpilih lama untuk digunakan dalam proses *pattern matching*. Hal ini membuka kemungkinan adanya *pair* baru terekstrak. Sama seperti proses sebelumnya, *pair* yang bobotnya melebihi nilai *threshold* digabung ke dalam pasangan kata relasi.

Iterasi dilakukan hingga korpus pasangan kata relasi jenuh atau dapat dikatakan *pair* baru yang masuk ke dalam korpus berjumlah sedikit. Pada penelitian ini, jika *pair* baru berjumlah kurang dari lima puluh maka iterasi akan berhenti. Evaluasi *pattern* dan *pair* dilakukan secara kolektif diakhir eksperimen. Anotator melakukan evaluasi secara manual untuk mengetahui kualitas *pattern* dan *pair* yang dihasilkan.

3.6 Metode Evaluasi

Penelitian ini tidak hanya menghasilkan korpus pasangan kata relasi hipernim-hiponim, namun juga *pattern* leksikal Bahasa Indonesia yang merepresentasikan relasi tersebut. Setelah suatu eksperimen selesai, evaluasi dilakukan terhadap *pattern* dan *pair* yang dihasilkan. Proses evaluasi dilakukan dengan bantuan anotator.

3.6.1 Evaluasi Pattern

Evaluasi *pattern* dilakukan dengan bantuan dua anotator dan melalui beberapa tahap. Berikut adalah proses yang dilakukan untuk evaluasi *pattern*.

1. Anotator membuat *pattern* secara manual yang diyakini dapat mengekstrak kata-kata relasi semantik sesuai dengan format *pattern* yang didefinisikan.
2. Anotator melakukan penilaian terhadap *pattern* yang dihasilkan oleh sistem. Suatu *pattern* dinilai berdasarkan jumlah *pair* benar maupun salah yang mungkin terekstrak dengan nilai antara 1 (sedikit), 2 (sedang), dan 3 (banyak).

3. Nilai *precision* diperoleh dengan membandingkan *pattern* yang dibentuk oleh anotator dan *pattern* yang dihasilkan sistem.

Pattern manual dibandingkan dengan *pattern* buatan sistem dengan melihat seberapa cocok keduanya. Suatu *pattern* dapat dikategorikan ke dalam tiga kelompok yaitu, *exact match*, *partial match*, atau *no match*. *Pattern* dikatakan *exact match* jika seluruh token dan urutannya dalam satu *pattern* adalah tepat sama dengan *pattern* yang lain. *Pattern* dikatakan *partial match* jika token dalam satu *pattern* adalah subbagian dari keseluruhan token untuk *pattern* lainnya, dimana urutan kemunculan diperhatikan. Sebagai contoh, *<hypernym>* adalah *<hyponym>* dan *<hyponym>* adalah sebuah *<hyponym>* dapat dikatakan *partial match*. *Pattern* dikatakan *no match* jika tidak memenuhi kriteria *exact match* maupun *partial match*.

Pattern hasil sistem diberi nilai anotasi berdasarkan dua dimensi, yaitu banyaknya *pair* benar yang dihasilkan dan banyaknya *pair* salah yang dihasilkan. Anotator memberi nilai anotasi dengan skala 1 hingga 3, dimana nilai 1 berarti *pair* berjumlah sedikit, nilai 2 berarti *pair* berjumlah sedang, dan nilai 3 berarti *pair* berjumlah banyak. Dari nilai anotasi, dibuat *confussion-matrix* untuk diketahui banyaknya *pattern* yang berkualitas tinggi.

3.6.2 Evaluasi Pair

Evaluasi *pair* dilakukan menggunakan teknik *random sampling*. Sejumlah *pair* yang dihasilkan diambil secara acak dan dianotasi dengan nilai 'benar' atau 'salah' oleh anotator. Berikut adalah proses dalam evaluasi *pair* hasil ekstraksi:

1. Terdapat tiga anotator berbeda yang menganotasi data yang sama.
2. Anotator memberi nilai benar atau salah terhadap suatu *pair* serta kategori yang didefinisikan. Untuk *pair* benar dapat termasuk kategori *pair* adalah *instance-class* atau *pair* adalah *class-class*. Untuk *pair* salah dapat termasuk kategori *pair* tanpa relasi, *pair* dengan relasi semantik lain, atau *pair* yang posisi *hypernym-hyponym*-nya terbalik.
3. Nilai Kappa dihitung untuk mengetahui tingkat persetujuan antar anotator. Perhitungan dilakukan menggunakan Fleiss' Kappa.
4. Hasil anotasi digunakan untuk menghitung akurasi *pair* yang dihasilkan sistem.

Dari setiap nilai anotasi, *pair* dimasukan ke dalam kategori yang lebih spesifik. Untuk data yang dianotasi benar, *pair* dapat dimasukan ke dalam dua kategori yaitu *instance-class* atau *class-class*. *pair* dimasukkan ke dalam kategori *instance-class* jika kata hyponym merupakan suatu instance, sementara kategori *class-class* jika kata hyponym merupakan suatu class. Untuk data bernilai salah, dapat dimasukan ke kategori salah tanpa hubungan, salah akibat posisi hiponim-hipernim terbalik (*false position*), atau salah dengan relasi semantik lain (*false relation*). Kategori salah akibat posisi hiponim-hipernim terbalik terjadi saat kedua kata yang terekstrak benar memiliki relasi semantik hiponim-hipernim namun kata yang menempati posisi hiponim seharusnya adalah hipernim, begitu pula sebaliknya. Suatu *pair* dapat digolongkan ke dalam kategori salah dengan relasi semantik lain jika kedua kata dalam *pair* tidak berhubungan hipernim-hiponim, namun memiliki relasi lain. Dalam penelitian ini, relasi lain hanya khusus dalam relasi semantik sinonim, antonim, atau meronym-holonym.

Akurasi *pair* dihitung dengan melihat label benar atau salah yang diberikan oleh anotator. Jika terdapat perbedaan anotasi maka dilakukan *voting* untuk menentukan label apa yang dipilih. Nilai akurasi dilihat terhadap seluruh eksperimen maupun setiap *pattern* yang digunakan.

BAB 4

IMPLEMENTASI

Bab ini menjelaskan secara detail proses implementasi dari pengolahan data, proses *pattern extraction* dan *matching*, pembobotan dan *ranking* baik *pattern* maupun *pair*.

4.1 Pembentukan Korpus Kalimat Wikipedia

Untuk dapat mengubah data XML Wikipedia menjadi kalimat dengan format yang diinginkan perlu melalui beberapa tahap. Gambar 4.1 memperlihatkan secara detail setiap tahapan dalam pemrosesan data Wikipedia. Pertama, data akan dibersihkan dari format *markup language* menggunakan WikiExtractor. Kemudian setiap baris yang merepresentasikan satu paragraf dipisahkan menjadi kalimat perbaris menggunakan program *sentence splitter*. Kalimat yang dihasilkan akan diformat menggunakan *rule-based formatter* sehingga sesuai dengan keinginan. Terakhir, POS Tagger akan memberikan *POS tag* untuk setiap token dalam kalimat.



Gambar 4.1: Pre-processing Data Wikipedia

Data XML yang diperoleh dari Wikipedia Dump diekstrak secara otomatis menggunakan WikiExtractor¹. WikiExtractor adalah program berbasis Python yang dibuat oleh Giuseppe Attardi dan Antonio Fuschetto. *Tools* ini akan membersihkan artikel Wikipedia dari format MediaWiki *markup language* (Gambar 3.2) sehingga dihasilkan korpus yang hanya berisi konten artikel saja. Program ini dapat diunduh dari Github dan dijalankan pada sistem operasi berbasis UNIX/Linux menggunakan perintah berikut.

Kode 4.1: Penggunaan Wiki Extractor

```
$ WikiExtractor.py xml-dump-file -o output-file
```

Jika tidak memberi spesifikasi opsi apapun, artikel yang dihasilkan membersihkan seluruh *markup language* dan hanya menyimpan isi artikel tanpa disertakan informasi seperti kategori, riwayat, dan versi artikel.

¹github.com/attardi/wikiextractor/wiki

4.1.1 Sentence Splitting

Korpus yang dihasilkan menghasilkan baris-baris yang merepresentasikan suatu paragraf dalam artikel Wikipedia. Pada penelitian kali ini, ingin dilihat relasi hipernim-hiponim antar dua kata pada kalimat yang sama. Untuk itu, perlu dilakukan proses *sentence splitting* yang dapat memisahkan setiap kalimat dalam paragraf. Hasil dari proses tersebut adalah dokumen yang terdiri dari baris-baris yang merepresentasikan satu kalimat.

Proses ini dilakukan dengan menggunakan program berbasis Perl yang telah dibuat sebelumnya oleh Setya (2016) dari Fasilkom UI, Indonesia. Ditambah satu program yang dapat secara otomatis melakukan *splitting* untuk seluruh dokumen dalam direktori. Berikut adalah contoh sebuah paragraf dalam artikel Wikipedia yang telah dibersihkan menggunakan WikiExtractor.

Charles Anthony Johnson (3 Juni 1829 - 17 Mei 1917), kemudian dikenal sebagai Charles Brooke memerintah Sarawak sebagai Raja Putih kedua dari 3 Agustus 1868 hingga meninggal dunia. Dia menggantikan pamannya, James Brooke sebagai raja.

Paragraf di atas akan dimasukkan ke program *sentence splitter*. Berikut adalah hasil yang diberikan dari proses tersebut.

Charles Anthony Johnson (3 Juni 1829 - 17 Mei 1917), kemudian dikenal sebagai Charles Brooke memerintah Sarawak sebagai Raja Putih kedua dari 3 Agustus 1868 hingga meninggal dunia.

Dia menggantikan pamannya, James Brooke sebagai raja.

4.1.2 Rule Based Formatter

Kalimat-kalimat yang terbentuk, selanjutnya diproses dengan program *rule based formatter* sehingga membentuk korpus dengan format yang diinginkan. Penambahan aturan juga untuk mengurangi ambiguitas dan bentuk usaha membentuk *pattern* yang lebih umum. Berikut adalah beberapa aturan tambahan untuk yang diberikan pada korpus Wikipedia.

1. Menghilangkan frasa yang berada di dalam tanda kurung.
Frasa yang terletak di dalam tanda kurung dapat dianggap sebagai penjelas kata atau frasa sebelumnya. Proses ini dilakukan agar dapat mengekstrak lebih banyak *pattern* yang sama.

2. Memisahkan simbol-simbol yang berhimpit pada awal dan akhir kata.

Beberapa token yang dipisahkan oleh spasi dalam kalimat merupakan kata yang berhimpit dengan tanda baca. Untuk mempermudah proses selanjutnya yaitu *sentence tagging*, dilakukan *pre-processing* tambahan yaitu memisahkan simbol-simbol *non-alphanumeric*.

3. Memberi penanda awal kalimat dengan '<start>' dan akhir kalimat dengan '<end>'.

Pemberian simbol awal dan akhir kalimat memperjelas isi kalimat dan juga menunjang proses *pattern extraction* dan *pattern matching*.

Dari contoh kalimat di atas, setelah melalui proses *formatting* yang didefinisikan menghasilkan kalimat berikut.

<start> Charles Anthony Johnson , kemudian dikenal sebagai Charles Brooke memerintah Sarawak sebagai Raja Putih kedua dari 3 Agustus 1868 hingga meninggal dunia . <end>
<start> Dia menggantikan pamannya , James Brooke sebagai raja . <end>

4.1.3 POS Tagging Kalimat Wikipedia

Proses *part-of-speech tagging* dilakukan pada korpus Wikipedia yang telah berbentuk kalimat dengan format yang didefinisikan. Pada penelitian ini, kelas kata yang menjadi pengamatan adalah *noun* (NN) dan *proper noun* (NNP), sehingga proses *POS Tagging* perlu dilakukan untuk mengidentifikasi kata-kata tersebut. Proses ini dijalankan menggunakan program Stanford POS Tagger (Toutanova et al., 2003) dan sebuah model Bahasa Indonesia yang merupakan hasil penelitian sebelumnya (Dinakaramani et al., 2014). Setelah selesai melalui proses *tagging* masih ditemui beberapa kesalahan *tagging* untuk beberapa token. Hal ini menyebabkan ditambahkannya *rule-based tagging* untuk memperbaiki kata-kata yang sering salah. Selanjutnya dilakukan penyesuaian format sehingga korpus yang dihasilkan lebih rapi dan terstruktur. Berikut adalah contoh kalimat yang sudah melalui tahap *POS Tagging*. Kalimat tersebut digunakan untuk proses *pattern matching*.

<start>_X Charles_NNP Anthony_NNP Johnson_NNP ,_Z kemudian_CC dikenal_VB sebagai_IN Charles_NNP Brooke_NNP memerintah_VB Sarawak_NNP sebagai_IN Raja_NNP Putih_NNP kedua_CD dari_IN 3_CD Agustus_NNP 1868_CD hingga_IN meninggal_VB dunia_NN ._Z <end>_X
--

4.2 Seed Builder

Proses pengumpulan *seed* dibantu dengan *resource* yang dimiliki WordNet Bahasa menggunakan *tools* nltk. Proses pengumpulan diawali dengan mengambil seluruh lema Bahasa Indonesia yang dimiliki oleh korpus nltk. Setelah itu, ambil seluruh *synset* yang mengandung lemma tersebut. Dari setiap *synset*, ambil relasi hipernimnya. Dari setiap *synset* hipernim, ambil lema Bahasa Indonesianya. Dilakukan pula filterisasi *synset* ataupun lema untuk mengurangi ambiguitas. Untuk setiap *synset* maupun lema yang diambil pada setiap tahapan, hanya boleh berasal dari kelas kata kerja (*noun*). Setelah didapatkan, bentuk ke dalam pasangan *tuple* biner. Berikut adalah

Kode 4.2: Algoritme pembentukan *seed*

```
buildSeed:
    ls = get_all_indonesian_lemma()
    for l in ls:
        syns = get_all_synsets(l)
        for s in syns:
            hs = get_all_hyponyms(s)
            for h in hs:
                hls = get_lemmas(h)
                for hl in hls:
                    filter(hl)
                    print_seed(l, hl)
```

Filterisasi dilakukan dengan tujuan mengurangi ambiguitas, namun tetap berusaha mendapatkan *seed* sebanyak mungkin. Filterisasi juga dilakukan untuk mendapatkan *seed* awal yang diyakini benar dan berkualitas baik. Salah satu bagian terpenting proses ini adalah memasangkan hanya lema yang merupakan *noun* ke lema yang juga adalah *noun*. Jika kemungkinan lema tersebut tergolong ke dalam kelas kata bukan *noun*, lema tidak diikutsertakan sebagai *seed* awal.

Tantangan dalam proses ini adalah banyak ditemukan kasus dimana satu lema dikandung oleh lebih dari satu *synset* atau satu *synset* memiliki lebih dari satu *synset* hipernim. Ambiguitas dalam kasus tersebut dapat mengurangi kualitas *seed* yang dihasilkan. Mengatahui hal tersebut, dibuatlah dua pendekatan berbeda untuk proses filterisasi *seed*.

Pendekatan pertama adalah tetap mengambil lemma yang sama pada *synset* hipernim yang berbeda. Hal ini dilatarbelakangi adanya lema yang berasal dari *synset* berbeda namun memiliki lema hipernim yang sama. Pada contoh (i), satu lema yang sama dimiliki oleh dua *synset* yang berbeda namun kedua *synset* tersebut memiliki *synset* hipernim yang sama. Lema untuk kedua *synset* hipernim juga sama

sehingga tetap diikutsertakan sebagai *seed*. Pada contoh (ii), satu lema berasal dari dua *synset* yang berbeda dan dua *synset* hipernim berbeda, namun ada lema yang sama yaitu 'lalu'. Sehingga pasangan '(pintu_masuk;lalu)' tetap diikutsertakan sebagai *seed*.


Pendekatan lainnya adalah dengan metode filterisasi yang *strict*. Jika satu lema memiliki lebih dari satu *synset* hipernim, maka lema tersebut dianggap ambigu dan langsung tidak diikutsertakan ke dalam *seed* awal. Berdasarkan tabel contoh lema, *synset*, dan hipernimnya, hanya contoh (i) yang diterima sebagai *seed* karena *synset* hipernim untuk lema tersebut sama. Sementara (ii) ditolak karena *synset* hipernim berbeda.

i.	(paruh, Synset(beak.n.02)) => ([bibir, kuala, muara], Synset(mouth.n.02)) (paruh, Synset(beak.n.01)) => ([bibir, kuala, muara], Synset(mouth.n.02))
ii.	(pintu_masuk, Synset(entrance.n.01)) => ([akses, capaian, lalu], Synset(access.n.03)) (pintu_masuk, Synset(orifice.n.01)) => ([koridor, lalu, lorong], Synset(passage.n.07))

Format penulisan $(l_1, S_1) \Rightarrow (l_2, S_2)$ dibaca l_1 adalah lema hiponim, S_1 adalah *synset* hiponim, l_2 adalah himpunan lema hipernim, dan S_2 adalah *synset* hipernim.

4.3 Sentence Tagging

Pada gambar 4.2 diperlihatkan bahwa tahap awal pembentukan *pattern* adalah melakukan *tagging* pasangan kata relasi ke dalam kalimat-kalimat Wikipedia.



Gambar 4.2: Proses Pembentukan *Pattern*

Data yang digunakan untuk proses ini adalah korpus Wikipedia tanpa *pos tag*. Beberapa tahapan dilakukan pada proses *tagging sentence* dengan pasangan kata relasi adalah sebagai berikut.

1. Dibaca seluruh pasangan kata relasi hipernim-hiponim.
2. Untuk setiap kalimat pada korpus Wikipedia, di cek apakah kalimat tersebut mengandung kedua kata dalam pasangan kata relasi.

3. Pengecekan dilakukan secara berulang untuk seluruh pasangan kata relasi karena terdapat kemungkinan satu kalimat mengandung lebih dari satu pasang kata relasi.
4. Kata-kata yang merupakan bagian dari pasangan kata relasi kemudian diberi *tag* sesuai relasinya dan disimpan ke dalam korpus berisi kalimat yang sudah memiliki *tag* hiponim dan hipernim.

Pada penelitian ini, satu kalimat yang telah di-*tag* hanya mengandung tepat satu pasangan kata relasi. Untuk kasus khusus dimana suatu pasangan kata relasi terdiri dari suatu kata yang merupakan sub kata pasangannya, maka pasangan kata tersebut tidak diikutsertakan untuk menghindari ambiguitas. Contoh pasangan kata yang tidak diikutsertakan adalah (*ikan gurame; ikan*) dimana kata 'ikan' terkandung dalam kedua kata relasi.

Berikut adalah contoh kalimat yang terbentuk dari proses *sentence tagging*. Diberikan pasangan kata relasi hipernim-hiponim (*fermion; partikel*) dan (*boson; partikel*) serta kalimat '<start> seluruh partikel dasar adalah boson atau fermion . <end>'. Hasil proses *sentence tagging* adalah sebagai berikut.

- <start> seluruh <hypernym>partikel<hypernym> dasar adalah boson atau <hyponym>fermion<hyponym> . <end>
- <start> seluruh <hypernym>partikel<hypernym> dasar adalah <hyponym>boson<hyponym> atau fermion . <end>

4.4 Pattern Extraction

Setelah mendapatkan kalimat-kalimat yang telah di-*tag* dengan kata relasi, ingin dicari *pattern* yang dapat digunakan untuk menambah jumlah relasi kata. Gambar 4.2 menunjukkan bahwa kalimat-kalimat tersebut selanjutnya masuk ke dalam proses *pattern extraction*. Pada penelitian ini, diusulkan pembuatan *pattern* menggunakan *standard tree* dengan beberapa modifikasi. Proses ini diimplementasi secara mandiri menggunakan program Java dengan mengikuti algoritma pemebentukan *tree* sederhana.

Suatu *node* merepresentasikan kata dalam kalimat dan dari satu kalimat terbentuk sebuah cabang dalam *tree*. *Node* menyimpan beberapa informasi seperti nama *node*, *parent*, *childs*, dan informasi identitas tambahan seperti apakah *node* tersebut merupakan relasi (hipernim atau *hyponym*) dan apakah *node* tersebut merupakan *leaf*. Untuk kata yang merupakan kata relasi, *node* menyimpan informasi jenis relasi beserta *list* dari kata yang merupakan bagian dari relasi tersebut.


Sebagai contoh jika terdapat beberapa *sequence* kalimat yang akan dibentuk ke dalam *tree* sebagai berikut menghasilkan *tree* seperti yang dapat dilihat pada gambar 4.3.

K1: <hyponym>piano<hyponym> adalah <hypernym>alat musik<hypernym>.

K2: <hyponym>Van Gogh<hyponym> adalah seorang <hypernym>pelukis<hypernym>.

K3: <hyponym>kucing<hyponym> adalah <hypernym>binatang<hypernym>.

K4: <hyponym>sepak bola<hyponym> adalah <hypernym>olahraga<hypernym>.



Gambar 4.3: Contoh *pattern tree* yang terbentuk

Dari *tree* di atas, terdapat dua *pattern* utama yang merepresentasikan korpus kalimat yaitu ‘<hyponym> adalah <hypernym>’ dan ‘<hyponym> adalah seorang <hypernym>’.

4.4.1 Informasi dalam Pattern

Satu *pattern* tidak hanya menyimpan informasi *sequence* kata yang merepresentasikan *pattern* tersebut, namun juga beberapa informasi tambahan lainnya. Informasi-informasi lain tersebut adalah jumlah kemunculan dalam korpus, *seed* unik yang membentuk *pattern*, dan kalimat unik yang membentuk *pattern*. Informasi-informasi tersebut digunakan untuk pembentukan vektor *pattern*, pemberian bobot *pattern*, dan melakukan *sorting* untuk mendapatkan *pattern* terbaik.

4.4.2 Pattern Tree

Pattern Tree adalah sebuah *tree* yang menyimpan seluruh *pattern* yang dihasilkan dari korpus, seperti yang telah dipaparkan pada gambar 4.3. Dalam pembuatan *pattern tree*, tidak perlu menyimpan seluruh kata dalam kalimat. Hanya *sequence* kata tertentu saja yang dianggap dapat menghasilkan *pattern* yang baik untuk diikutsertakan. Maka dari itu, perlu diketahui *sequence* kata dalam kalimat yang cocok digunakan sebagai *pattern*. Berikut adalah tiga pendekatan yang digunakan dalam penelitian ini dengan contoh kalimat dasarnya yaitu ‘<start> <hyponym>singa<hyponym> adalah <hypernym>kucing<hypernym> yang berukuran besar . <end>’.

1. Hanya memperhatikan kata yang berada diantara pasangan kata relasi.

Pada kasus ini, hanya ingin dilihat kata-kata yang berada diantara kata yang merupakan hipernim-hiponim atau hipernim-hiponim. Kata-kata diantara dua relasi dapat dianggap paling dekat jika ingin mencari *memisahkan* setiap relasi tersebut. Pada contoh diatas, *sequence* kata yang dihasilkan adalah ‘<hyponym>singa<hyponym> adalah <hypernym>kucing<hypernym>’

2. Mengikutsertakan n kata sebelum kata relasi pertama.

Beberapa kata berbasis Perl sebelum program dapat memberikan informasi untuk yang dapat meningkatkan kualitas satu program. Pada contoh kalimat diatas dengan ($n = 1$), *sequence* kata yang dihasilkan adalah ‘<start> <hyponym>singa<hyponym> adalah <hypernym>kucing<hypernym>’

3. Mengikutsertakan n kata setelah kata relasi terakhir.

Tipe ini sama dengan sebelumnya, namun dilihat pengaruh kata-kata yang mengikuti kata relasi. Pada contoh kalimat diatas dengan ($n = 1$), *sequence* kata yang dihasilkan adalah ‘<hyponym>singa<hyponym> adalah <hypernym>kucing<hypernym> yang’

Suatu kalimat akan di-*parse* ke dalam bentuk *array* yang elemennya merepresentasikan kata dalam kalimat. Proses *parsing* dilakukan berdasarkan spasi antar kata. Dari *array* yang terbentuk, dicari bagian-bagian yang akan dimasukan ke dalam *pattern tree* sesuai dengan pendekatan yang dipilih. Jika hanya memperhatikan kata diantara pasangan kata relasi maka bagian-bagian lain tidak masuk ke dalam *pattern tree*. Begitu jika dipilih pendekatan dengan n kata sebelum atau setelah pasangan kata. Dari *pattern tree* yang terbentuk, dapat didaftarkan seluruh

pattern serta bobot untuk *pattern* tersebut. Kode 4.3 menunjukkan secara rinci proses penambahan suatu *pattern* ke dalam *pattern tree*.

Kode 4.3: Penambahan *pattern* ke dalam *pattern tree*

```

sentence = #kalimat baru yang akan dimasukan
type = #pendekatan yang dipilih
ptree = #pattern tree yang sudah terbentuk

addNewPattern(sentence, type, ptree):
    sentence_arr = split(sentence, ' ')
    index = getIndexToken(sentence_arr, type)
    addPattern(ptree, sentence_arr, index)

getIndexToken(sentence_arr, type):
    sentence_arr = tokenize_sentence(sentence)
    index = (start, end)
    if (type == inbetween):
        for(i = 0..sentence_arr.size()):
            if (token == relation):
                if (!start) start = i
                else end = i
    else if (type == n before):
        index = getIndexToken(sentence_arr, inbetween)
        if (index.start - n >= 0)
            index.start -= n
        else index.start = 0
    else if (type == n after):
        index = getIndexToken(sentence_arr, inbetween)
        if (index.end + n < sentence_arr.size())
            index.end += n
        else index.end = sentence_arr.size()
    return index

```

4.4.3 Vektor Pattern

Suatu *pattern* dapat direpresentasikan menjadi vektor berdasarkan nilai-nilai yang dimilikinya. Vektor ini dimanfaatkan untuk melakukan pengurutan terhadap seluruh *pattern* yang dihasilkan. Selain itu, nilai-nilai pada vektor *pattern* juga digunakan untuk melakukan filterisasi. Fitur utama pada vektor *pattern* diambil dari informasi yang disimpan *pattern*, yaitu total kemunculan *pattern*, jumlah *seed* unik, dan jumlah kalimat unik yang membentuk *pattern* tersebut. Fitur lainnya adalah hasil kombinasi perbandingan antar nilai-nilai utama, yaitu nilai perbandingan antara jumlah

seed unik dibagi jumlah kalimat unik, nilai perbandingan antara jumlah *seed* untuk dibagi total kemunculan, dan nilai perbandingan antara jumlah kalimat unik dibagi total kemunculan.

4.4.4 Validasi Pattern

Setelah terbentuk *pattern tree*, perlu didaftar seluruh *pattern* yang dihasilkan. Proses pembentukan *pattern* cukup dengan menelusuri *path* dari *node leaf* hingga *root*. *Pattern* yang dihasilkan berjumlah banyak, sayangnya tidak seluruh *pattern* yang dihasilkan berkualitas baik. Untuk mengurangi jumlah *pattern* yang kurang baik, dilakukan proses filterisasi. Beberapa aturan yang harus dipenuhi agar suatu *pattern* diterima adalah sebagai berikut.

- Harus ada minimal satu kata diantara dua kata relasi.
Banyak kasus dimana dua kata relasi hanya dipisahkan oleh spasi. *Pattern* yang hanya mengandung spasi tidak memberikan informasi apapun karena simbol spasi dalam Bahasa Indonesia digunakan sebagai pemisah antar kata. Sebagai contoh kalimat hasil *tagging* ‘<start> semua jenis <hypernym>ular<hypernym> <hyponym>beludak<hyponym> memiliki taring yang panjang <end>’ tidak akan menghasilkan *pattern* yang *valid*.
- Nilai dalam vektor *pattern* harus memenuhi nilai *threshold* yang didefinisikan.
Nilai perbandingan antara jumlah *seed* unik dibagi jumlah kalimat unik lebih dari 0.5. Nilai perbandingan antara jumlah *seed* unik dibagi total kemunculan lebih dari 0.2. Nilai perbandingan antara jumlah kalimat unik dibagi total kemunculan harus lebih dari 0.7. Ketiga nilai *threshold* tersebut didefinisikan mandiri berdasarkan pengamatan dari nilai-nilai pada vektor *pattern*. Nilai tersebut mengeliminasi sejumlah *pattern* yang terbentuk dari banyak kalimat namun variasi *seed* yang menghasilkannya sedikit.

4.4.5 Pembentukan Pattern Unik

Pattern yang dihasilkan dari tahap ini harus unik sehingga tidak terjadi ambiguitas jika hendak digunakan. Pada masa awal pengembangan, masalah yang muncul pada *pattern* yang dihasilkan adalah adanya *pattern* yang posisi hipernim-hiponimnya saling berkebalikan. Sebagai contoh beberapa *pattern* ambigu yang dihasilkan seperti (i) <hyponym> adalah <hypernym>, (ii) <hypernym> adalah <hyponym>, (iii) <hypernym> dan <hyponym>, dan (iv) <hyponym> dan <hy-

pernym>. Kata-kata pada kalimat yang menempati posisi hipernim-hiponim tersebut nantinya digantikan dengan kata yang kemunculannya sesuai dengan *pattern* yang diberikan. Sehingga perlu ada strategi tambahan untuk mengatasi masalah tersebut.

Strategi yang diusulkan dalam penelitian ini untuk mengatasi masalah ambiguitas antar *pattern* adalah membangun suatu arsitektur yang dapat mengidentifikasi dan menyelesaikan. Berikut adalah tahapan yang dilakukan untuk memastikan bahwa *pattern* yang dihasilkan adalah unik.

1. Dicari *pattern* dengan pendekatan hanya memperhatikan kata-kata diantara pasangan kata relasi.
2. *Pattern* yang dihasilkan, dibandingkan satu dengan yang lain. Jika terdapat *pattern* mengandung *tag* hipernim-hiponim yang saling terbalik, *pattern* yang bersangkutan dikeluarkan dari daftar *pattern* unik untuk kemudian dievaluasi ulang.
3. Proses evaluasi ulang dilakukan menggunakan pendekatan pembuatan *pattern* lainnya yaitu dengan memperhatikan n kata sebelum dan setelah kata hipernim-hiponim. Hasil dari kedua pendekatan digabung dan dicek apakah *pattern* tersebut dibutuhkan. Suatu *pattern* dinyatakan dibutuhkan jika *substring* dari *pattern* tersebut termasuk dalam *list pattern* yang membutuhkan evaluasi ulang.
4. Proses evaluasi dilakukan secara berulang dari hingga iterasi ke- n .

Setelah melakukan tahapan di atas, tidak ada lagi kasus posisi relasi saling tertukar dari *pattern* yang dihasilkan. Daftar *pattern* unik yang dihasilkan kemudian diurutkan berdasarkan bobot sebelum ditampilkan.

4.4.6 Pengurutan Pattern


Setelah terbentuk *pattern* yang sesuai, dilakukan proses pengurutan (*sorting*) untuk mengetahui *pattern* mana yang terbaik berdasarkan informasi dalam vektor *pattern*. Proses pengurutan dilakukan dengan membandingkan satu *pattern* dengan yang lain, dengan tahapan sebagai berikut.

1. Semakin besar jumlah kalimat unik yang membentuk *pattern*.
2. Semakin besar nilai perbandingan antara jumlah *seed* unik yang membentuk *pattern* dengan jumlah kalimat unik yang membentuk *pattern*.

3. Semakin sedikit jumlah token dalam *pattern* jika di-parse menggunakan spasi.

4.5 Pattern Matching

Proses ekstraksi *pair* baru dilakukan dengan menggunakan metode *pattern matching* seperti yang dapat dilihat pada gambar 4.4. *Pattern* yang terbentuk dari proses *pattern extraction* digunakan untuk menambah jumlah pasangan kata relasi dengan dilakukan proses *pattern matching* terhadap korpus Wikipedia. Proses *pattern matching* dilakukan menggunakan algoritma *Suffix Tree* dengan modifikasi. Implementasi dilakukan secara mandiri menggunakan program berbasis Java.



Gambar 4.4: Proses ekstraksi *pair*

Pembentukan *suffix tree* mirip seperti pembentukan *pattern tree* yaitu diawali dengan melakukan *parsing* sehingga satu kalimat direpresentasikan dalam bentuk *array*. Dari *array* yang dihasilkan, dibentuk sebuah *suffix tree* yang merepresentasikan kalimat tersebut. Sebuah *node* dalam *tree* merepresentasikan satu kata dalam kalimat. *Suffix tree* selanjutnya dicocokkan dengan *pattern* yang diberikan. Jika terdapat *path* dalam *tree* yang sesuai dengan *pattern*, dibentuk *pair* yang merepresentasikan pasangan kata relasi hipernim-hiponim yang dihasilkan. Selain kata hipernim-hiponim, *pair* juga menyimpan informasi lain seperti total dokumen unik, daftar kalimat unik, dan daftar *pattern* unik yang menghasilkan *pair* tersebut. Berikut adalah tahapan yang dilakukan program jika diberikan satu kalimat dan satu *pattern*.

1. Kalimat masukan dibentuk menjadi suatu *suffix tree*.
2. *Pattern* masukan ditokenisasi ke dalam bentuk *list* kata. *Pattern* pasti mengandung token <hypernym> dan <hyponym>, selanjutnya disebut token relasi.
3. Jika ditemukan token relasi pada daftar token *pattern* yang sedang dievaluasi, maka *node* yang dikunjungi disimpan sementara sesuai dengan relasinya.

4. Jika token bukan token relasi, maka di evaluasi apakah token sama dengan *node* yang dikunjungi. Jika sama maka proses evaluasi dilanjutkan, namun jika berbeda maka *pattern* tidak cocok.
5. Jika seluruh token *pattern* telah dievaluasi dan tidak mengalami kegagalan, maka dianggap berhasil dan kata yang terekstrak disimpan dalam bentuk *pair*.

Pada masa awal pengembangan, masalah pertama yang ditemukan adalah banyaknya *pair* yang salah satu atau kedua kata relasinya tidak termasuk dalam kelas kata benda. Beberapa *pair* yang salah diantaranya (*Menoitios;salah*) dimana 'salah' adalah *adjective* dan (*saya,gitaris*) dimana 'saya' adalah preposisi. Untuk itu diputuskan menggunakan korpus Wikipedia yang sudah melalui tahap POS Tagging. *POS tag* pada setiap kata dalam kalimat membatasi proses *pattern matching* hanya akan mengekstrak *pair* yang kedua katanya berada dalam kelas kata benda (*noun* atau *proper noun*).

Masalah lain yang ditemukan adalah jika kata yang ingin diekstrak merupakan *multi token*. *Pair* kurang baik yang dihasilkan sebelum mengatasi masalah ini diantaranya adalah (*bola;olahraga*) yang seharusnya (*sepak bola;olahraga*), (*Serikat;negara*) yang seharusnya (*Amerika Serikat;negara*), dan (*Monterrey,ibu*) yang seharusnya (*Monterrey;ibu kota*). Solusi yang digunakan untuk mengatasi masalah ini adalah dengan mengasumsikan kata-kata berurutan yang tergolong dalam kelas kata yang sama dalam suatu kalimat merupakan *multi token*. *Multi token* disimpan dalam satu *node* pada pembentukan *suffix tree*.

Untuk dapat mengidentifikasi *multi token*, penyesuaian dilakukan pada tahap *parsing* kalimat menjadi *array*. Satu token akan bergabung dengan token sebelumnya jika memiliki *pos tag* yang sama. Proses ini menghasilkan satu *array* yang merepresentasikan kalimat dimana setiap elemen dalam *array* dapat merupakan *single token* maupun *multi token*. Kode 4.4 memaparkan proses pembentukan *array* yang digunakan untuk membangun *suffix tree*.

Kode 4.4: Proses *parsing* kalimat menjadi *array*

```
sentence = #kalimat yang akan dievaluasi

getSentenceArray(sentence):
    tmp_arr = split(sentence, ' ')
    sentence_arr = []
    prev = null
    i = 0
    for s in sentence_arr:
        if (sentence.tag == prev.tag):
```

```

        sentence_arr[i-1] += `` ' ' + s
    else
        sentence_arr[i].add(s)
    i++
    prev = s
return sentence_arr

```

4.5.1 Vektor Pair

Suatu *pair* dapat direpresentasikan ke dalam bentuk vektor berdasarkan nilai-nilai yang dimilikinya. Nilai-nilai fitur yang dimiliki oleh sebuah *pair* adalah total kemunculan *pair*, total dokumen yang membentuk *pair*, jumlah *pattern* unik, dan jumlah kalimat unik. Untuk memperkaya fitur *pair*, dilakukan pula Word Embedding. Nilai *similarity* antar dua kata relasi ditambahkan sebagai sebagai salah satu fitur.

4.5.2 Filterisasi Pair

Pair baru yang dihasilkan untuk proses ini berjumlah sangat banyak, namun tidak semua *pair* yang dihasilkan adalah benar merupakan pasangan kata yang memiliki relasi semantik hipernim-hiponim. Beberapa *pair* kebetulan terekstrak akibat memenuhi *pattern* leksikal yang sama dengan salah satu *pattern* yang digunakan. Untuk mengeliminasi data yang tidak diyakini benar, dilakukan proses filterisasi sederhana terhadap setiap *pair* yang dihasilkan. *Pair* diyakini tidak terbentuk secara kebetulan jika terdapat lebih dari satu *pattern* yang mengekstrak *pair* tersebut.

Setelah mengeliminasi *pair* yang hanya terbentuk dari satu *pattern*, selanjutnya dilakukan pembobotan menggunakan rumus 4.1. Jika nilai bobot melebihi *threshold*, maka *pair* dimasukan ke dalam korpus pasangan kata relasi. Nilai *threshold* sendiri menjadi salah satu masukan dalam parameter eksperimen.

$$Bobot = \left(\frac{\text{jumlah pattern pembentuk pair}}{\text{jumlah pattern digunakan}} + \text{similarity score} \right) / 2 \quad (4.1)$$

Pair yang lolos filterisasi akan bergabung ke dalam korpus pasangan kata relasi semantik hipernim-hiponim.

4.6 Pemodelan Word Embedding

Untuk menambah fitur pada vektor *pair* yang dapat menunjang proses evaluasi, dilakukan Word Embedding. Implementasinya menggunakan model Word2Vec

berbasis Python. Proses ini dibuat secara otomatis dengan hanya memberi masukan dokumen Bahasa Indonesia berukuran besar. Dalam penelitian ini, dokumen Bahasa Indonesia yang digunakan adalah korpus Wikipedia yang telah di proses membentuk kalimat.

Model dibuat memanfaatkan korpus Wikipedia yang telah melalui proses POS Tagging. Korpus tersebut diolah sedemikian sehingga kata-kata yang dianggap *multi word*, memiliki kelas kata sama berurutan, digabung dengan simbol garis awah ('_'). Hal ini dilatarbelakangi atas hasil *pair* yang banyak merupakan *multi word*. Jika hal ini tidak dilakukan, maka akan banyak kata yang tidak ditemukan dalam *dictionary* yang dihasilkan model *word embedding*. Kode 4.5 menunjukkan proses pembuatan model *word embedding*.

Kode 4.5: Kode pembangunan model *word embedding*

```
sentences = #kumpulan kalimat yang menjadi model

import gensim

min_count = 1 #jumlah minimum kata
size = 123 #panjang vektor
window = 5 #ukuran window
model = gensim.models.Word2Vec(sentences, min_count=1, size=123,
                               window=5);

model.save(nama_berkas)
```

Model yang terbentuk, digunakan untuk memberi nilai *similarity* antara kata hipernim-hiponim dalam satu *pair*. Proses pencarian nilai *similarity* dilakukan secara kolektif untuk setiap iterasi. Model yang terbentuk dibaca kemudian dicari *similarity* untuk setiap pasang kata relasi hipernim-hiponim. Hal ini diharapkan dapat memberi informasi lebih terhadap kualitas *pair* yang dihasilkan.

BAB 5

EVALUASI DAN HASIL

Bab ini menjelaskan mengenai hasil untuk setiap tahapan penelitian, deskripsi percobaan yang telah dilakukan, serta evaluasi dan hasil terkait percobaan tersebut.

5.1 Hasil Pengolahan Data Wikipedia

Sebelum digunakan sebagai korpus masukan dalam proses *pattern matching* dan *extraction*, data Wikipedia perlu dikumpulkan dan diproses terlebih dahulu sehingga memenuhi format yang diinginkan.

5.1.1 Pengumpulan Data Wikipedia

Korpus teks dokumen utama dalam penelitian ini adalah artikel Wikipedia. Korpus diunduh dari situs Wikimedia. Berkas yang digunakan adalah `idwiki-20170201-pages-article-multistream.xml.bz2`, diunduh pada 20 Februari 2017. Berkas tersebut berukuran 398.6 MB dan merupakan data artikel Wikipedia Bahasa Indonesia hingga tanggal 1 Februari 2017. Setelah di-*extract*, ukuran asli berkas XML tersebut adalah 1.9 GB. Berkas tersebut mengandung seluruh *tag* identitas Wikipedia dan ditulis dalam format metadata Wikipedia.

5.1.2 Ekstraksi Teks

Proses ekstraksi teks dilakukan karena tidak seluruh bagian teks digunakan sebagai data penelitian. Data wikipedia yang ingin digunakan hanya isi artikel. Korpus Wikipedia diekstrak menggunakan WikiExtractor untuk menghilangkan *tag* yang tidak digunakan. Selain itu, artikel Wikipedia juga perlu dibersihkan dari simbol-simbol metadata. Setelah dilakukan proses ini, total ukuran berkasi Wikipedia menjadi 424 MB.

5.1.3 Pembentukan Kalimat

Data hasil ekstraksi memisahkan satu paragraf untuk setiap baris, sementara format yang diinginkan adalah satu baris merepresentasikan satu kalimat. Digunakan

program *sentence splitter* untuk memisahkan kalimat dalam berkas Wikipedia. Kemudian, dilanjutkan ke dalam proses *rule-based formatter* sehingga memberi hasil kalimat yang sudah sesuai format yang ditentukan. Proses tersebut menghasilkan 3.696.339 kalimat dengan total ukuran berkas 431 MB. Berkas ini digunakan sebagai masukan proses *pattern extraction*.

5.1.4 Hasil POS Tagging Kalimat

Kalimat-kalimat yang telah dibentuk, dimasukan ke dalam program POS Tagger, sehingga dihasilkan kalimat yang setiap tokennya memiliki *tag* berdasarkan kelas kata. Total ukuran berkas adalah 623 MB. Berkas ini digunakan sebagai masukan proses *pattern matching*. Sebelum diberi *rule* tambahan, masih ditemukan beberapa kata yang di-*tag* salah sehingga berakibat terekstraksi pula *pair* yang salah.

5.1.5 Pemodelan Word Embedding

Pembuatan model *word embedding* menggunakan korpus Wikipedia yang sudah berbentuk kalimat. Model yang digunakan adalah Word2Vec dengan *tools* gensim. Proses ini menghasilkan tiga berkas model (tabel 5.1). Berkas hasil pemodelan berukuran besar karena menggunakan seluruh kalimat yang ada dalam korpus Wikipedia.

Tabel 5.1: Berkas model *word embedding*

Nama Berkas	Jenis Berkas	Ukuran Berkas
model-word2vec	File	306.1 MB
model-word2vec.syn0.npy	NPY File	1.8 GB
model-word2vec.syn1neg.npy	NPY File	1.8 GB

5.2 Pengumpulan dan Evaluasi Seed

Pasangan kata relasi hipernim-hiponim awal diambil dari korpus yang dimiliki oleh WordNet Bahasa. Setelah melalui proses pembentukan *seed*, berikut adalah jumlah *seed* yang dihasilkan berdasarkan jenis filterisasi. Kedua tipe *seed* tersebut digunakan proses pembentukan pattern pada iterasi pertama.

Tabel 5.2: Jumlah *seed* hasil ekstraksi

No	Jenis Filterisasi	Jumlah Seed
1.	lema sama	8.985
2.	<i>strict</i>	8.602

Walau sudah melakukan proses filterisasi sebagai upaya mengurangi *error* dan ambiguitas yang terjadi pada proses penentuan *seed* serta untuk meningkatkan kualitas *seed*, masih ada hambatan yang belum dapat diatasi dalam penelitian ini. Beberapa kelemahan dari *seed* awal yang dihasilkan adalah sebagai berikut.

- *Seed* yang mengandung kata bukan Bahasa Indonesia. Korpus yang ingin dibuat berdomain Bahasa Indonesia, namun *seed* yang dihasilkan mengandung Bahasa Melayu atau Bahasa Indonesia lama. Beberapa kata bukan Bahasa Indonesia yang dihasilkan adalah ‘had’, ‘bonjol’, dan ‘cecok’.
- Kesalahan semantik *synset* dan lema Bahasa Indonesia. Beberapa *synset* nltk memiliki lema Bahasa Indonesia yang kurang sesuai jika dilihat secara semantik. Sebagai contoh *Synset('scholar.n.01')* dengan lemma Bahasa Indonesia ‘buku_harian’, ‘pelajar’. Dalam Bahasa Indonesia, ‘buku_harian’ memiliki makna yang berbeda dengan ‘pelajar’.
- Kesalahan lema Bahasa Indonesia untuk suatu *synset* menyebabkan dihasilkannya *seed* yang jika dievaluasi kualitatif oleh manusia dirasa kurang tepat. Contoh *seed* yang tidak baik adalah dari pemetaan (*‘sejarawan’, Synset('historian.n.01')*) => ([*‘buku_harian’, ‘pelajar’*], *Synset('scholar.n.01')*) dihasilkan *seed* (*sejarawan, buku harian*) dan (*sejarawan, pelajar*). *Seed* (*sejarawan, buku harian*) adalah salah karena kedua kata tidak berelasi hipernim-hiponim.

Walau terlihat masih banyak ditemukan kasus salah seperti di atas, beberapa pasangan kata yang terbentuk dapat dinilai cukup baik. Beberapa *seed* baik yang berhasil dibentuk adalah ‘(lori,truk)’, ‘(kecap,bumbu)’, ‘(itik,unggas)’, dan ‘(kelelawar,mamalia)’.

5.3 Pembentukan Pattern Pertama

Iterasi pertama untuk seluruh percobaan selalu menggunakan *seed* di atas, sehingga hasil untuk proses pembentukan *pattern* selalu sama. Berikut adalah detail hasil untuk *sentence tagging* dan *pattern extraction* pada iterasi pertama.

5.3.1 Sentence Tagging dengan Seed

Dari kedua tipe *seed* hasil filterisasi, masing-masing digunakan untuk membentuk korpus kalimat yang memiliki *tag* relasi hipernim-hiponim. Berikut adalah hasil proses *sentence tagging* menggunakan kedua tipe *seed*.

Tabel 5.3: Hasil *sentence tagging* dengan *seed*

No.	Jenis Seed	Jumlah kalimat	Jumlah kalimat unik	Ukuran berkas
1.	Seed dengan filterisasi lema sama	69.574	29.977	14 MB
2.	Seed dengan filterisasi strict	64.718	25.378	13 MB

Data pada tabel 5.3 memperlihatkan bahwa banyak ditemukan kasus dimana satu kalimat mengandung lebih dari satu pasangan kata relasi. Sementara, jika dibandingkan dengan keseluruhan kalimat dalam Wikipedia, hanya sekitar 0.01 yang mengandung *seed*. Hal ini dapat berarti banyak kalimat yang kurang merepresentasikan relasi atau banyak *seed*. Selain itu, data di atas juga dapat disebabkan masih banyak *seed* kurang baik yang terbentuk seperti yang sudah dijelaskan pada bab 5.2.

5.3.2 Hasil Pattern Extraction

Kedua korpus kalimat yang masing-masing menghasilkan daftar *pattern*. Kedua daftar *pattern* digabung dan diurutkan sesuai bobot. Dari 106 *pattern* yang dihasilkan pada iterasi pertama, tabel 5.4 memaparkan lima *pattern* terbaik yang digunakan untuk proses *pattern matching*. Kolum ‘Jumlah Seed’ merepresentasikan jumlah *seed* unik yang membentuk *pattern* tersebut.

Tabel 5.4: Pattern terbaik iterasi pertama

Pattern	Jumlah Seed
start <hyponym> adalah <hypernym>	87
<hyponym> merupakan <hypernym>	35
<hyponym> adalah <hypernym> yang	35
<hypernym> seperti <hyponym> dan	16
<hypernym> termasuk <hyponym>	17

Dari data di atas, dapat dilihat bahwa *seed* yang membentuk *pattern* terbaik dapat dikatakan sedikit dibanding jumlah *seed* total yang terbentuk. Hal ini membuktikan bahwa masih banyak *seed* kurang baik yang terbentuk pada tahap pembangunan *seed*.

Kelima *pattern* tersebut dibentuk dari total 104 *seed* unik dimana *seed* tersebut langsung masuk ke korpus pasangan kata relasi. Dari 140 *seed* yang merepresentasikan kelima *pattern*, kemudian dicari nilai akurasinya. Diambil 20 *pair* secara acak sehingga satu sampel merepresentasikan 7 data asli, kemudian *pair* tersebut dianotasi secara manual oleh tiga anotator. Total sampel yang benar adalah 18 data, sehingga dapat dikatakan bahwa akurasi *pair* pertama yang masuk ke dalam korpus pasangan kata relasi adalah 0.9. Jika dilihat dari keseluruhan data, masih terdapat 14 *pair* yang salah namun masuk ke dalam pasangan kata relasi. Hal ini berarti walau sudah dilakukan proses filterisasi, korpus *seed* yang dihasilkan masih mengandung *error*. Contoh *seed* yang salah adalah ‘(aorta;arteri)’ yang lebih cocok dikategorikan ke dalam relasi holonim-meronim dan ‘(atmosfer;bagian)’ yang kurang jelas artinya.

5.4 Hasil Eksperimen

Bagian ini akan memaparkan skenario untuk setiap eksperimen yang telah dilakukan dan hasil dari eksperimen tersebut. Setiap eksperimen dilakukan dengan memodifikasi parameter dalam arsitektur *semi-supervised* yaitu mengubah nilai *threshold* dalam filterisasi *pair* baru atau mengubah tipe *pair* yang diterima antar *single token* dan *multi token*.

5.4.1 Eksperimen 1

Eksperimen pertama dilakukan dengan nilai *threshold* untuk filterisasi *pair* baru sebesar 0.6. Percobaan pertama menerima seluruh tipe kata, baik yang merupakan *multi token* maupun *single token*. Tabel 5.5 menampilkan total *pattern* yang dihasilkan dan digunakan untuk setiap iterasi. Sementara tabel 5.6 menampilkan rincian jumlah *pair* yang dihasilkan dan diterima untuk setiap iterasi.

Tabel 5.5: Pattern Hasil Eksperimen 1

Iterasi ke-	Total pattern	Pattern untuk ekstraksi
1	106	Pattern utama
2	347	<start> <hyponym> merupakan <hypernym>
3	395	<hyponym> merupakan <hypernym> yang
4	425	<hypernym> atau <hyponym>

Tabel 5.6: Pair Hasil Eksperimen 1

Iterasi ke-	Total Pair	Pair baru	Korpus Pasangan kata relasi
1	82409	799	939
2	104389	316	1255
3	108397	175	1430
4	108542	2	1432

Data di atas memperlihatkan bahwa jumlah *pair* yang diyakini benar atau nilai bobotnya melebihi *threshold* dapat dikatakan sedikit jika dibandingkan dengan total *pair* yang terekstraksi. Perbandingan total *pair* yang masuk ke dalam korpus pasangan kata relasi dengan total *pair* yang dihasilkan oleh sistem hanya 0.013. Untuk meningkatkan jumlah *pair* yang masuk ke dalam korpus pasangan kata relasi, dilakukanlah eksperimen 2 dimana nilai *threshold* diturunkan.

Selanjutnya setelah dihitung akurasi sampel *pair* yang dihasil dalam eksperimen ini (tabel 5.12), *pair* yang kata hipernim dan hiponimnya merupakan *single token* ada sejumlah 73 *pair*. Setelah dianotasi, 63 diantaranya adalah *pair* yang berlabel benar. Hal ini menunjukkan akurasinya untuk *pair* yang bertipe *single token* adalah 0.86. Kemudian dari data tersebut, 44 *pair* adalah pasangan kata hipernim-hiponim yang keduanya merupakan konsep. Hal tersebut memperlihatkan bahwa *pair* yang kedua katanya merupakan *single token* memiliki kualitas yang jauh lebih baik dibanding *multi token*. Untuk membuktikan hal tersebut, dilakukan eksperimen 3 yang hanya memperhatikan data yang merupakan *single token*.

5.4.2 Eksperimen 2

Melihat sedikitnya jumlah pattern yang dihasilkan dari eksperimen pertama, maka diputuskan untuk menurunkan sedikit nilai *threshold*. Nilai *threshold* untuk filterisasi *pair* baru menjadi sebesar 0.55. Penurunan nilai yang hanya 0.05 dilakukan untuk menjaga kualitas *pair* yang dihasilkan. Tabel 5.7 dan 5.8 memaparkan hasil dari eksperimen kedua.

Tabel 5.7: Pattern Hasil Eksperimen 2

Iterasi ke-	Total pattern	Pattern baru terpilih
1	106	Pattern utama
2	699	<start> <hyponym> merupakan <hypernym>
3	791	<hyponym> merupakan <hypernym> yang
4	842	<hyponym> menjadi <hypernym>

Tabel 5.8: Pair Hasil Eksperimen 2

Iterasi ke-	Total Pair	Pair baru	Korpus Pasangan kata relasi
1	82409	2053	2193
2	104389	878	3071
3	108397	413	3484
4	108737	9	3493

Jika dibandingkan dengan eksperimen pertama, jumlah *pair* yang nilainya melebihi *threshold* bertambah hingga dua kali dari sebelumnya walaupun selisih nilai *threshold* hanya 0.05. Ini berarti banyak *pair* yang nilai bobotnya dekat dengan nilai batas tersebut. Selanjutnya, jika dilihat dari total *pair* yang diekstrak, hingga iterasi ke-3 jumlahnya total *pair* yang terekstrak sama. Perubahan terjadi pada iterasi ke-4 ketika *pattern* yang digunakan berubah. Hal ini berarti jumlah total *pair* yang terekstrak sepenuhnya bergantung dengan *pattern* yang digunakan.

5.4.3 Eksperimen 3

Setelah menganalisis secara kualitatif *pair* yang dihasilkan, banyak *pair* yang kata hipernimnya adalah konsep sementara kata hiponimnya adalah *instance*. Untuk relasi semantik hipernim-hiponim yang umum, hubungan antar kata yang diinginkan adalah antar konsep. Untuk pasangan kata relasi hipernim-hiponim yang bertipe konsep-konsep, lebih banyak dijumpai jika kedua kata merupakan *single token*. Selain itu, pembentukan *multi token* yang dilakukan belum sepenuhnya baik seperti banyaknya dijumpai kasus terbentuk kata yang kelebihan token. Eksperimen ini akan mencoba mengekstrak *pair* yang kedua katanya adalah *single token*. Nilai *threshold* yang digunakan sama seperti eksperimen 2 yaitu 0.55.

Tabel 5.9: Pattern Hasil Eksperimen 3

Iterasi ke-	Total pattern	Pattern baru terpilih
1	106	Pattern utama
2	437	<hyponym> adalah sebuah <hypernym>

Tabel 5.10: Pair Hasil Eksperimen 3

Iterasi ke-	Total Pair	Pair baru	Korpus Pasangan kata relasi
1	10267	298	438
2	11262	21	459

Untuk *pair* yang hanya *single word* sudah pasti jumlahnya jauh lebih sedikit. Jika dibandingkan dengan dua eksperimen sebelumnya, total *pattern* yang dihasilkan juga jauh lebih sedikit. Hal ini memperlihatkan bahwa jumlah pasangan kata yang digunakan mempengaruhi jumlah *pattern* yang dihasilkan, dimana semakin banyak jumlah pasangan kata relasi maka semakin banyak pula *pattern* yang dihasilkan. Tabel diatas juga memperlihatkan bahwa iterasi total yang dijalankan dalam eksperimen ini sangat sedikit yaitu hanya dua iterasi.

5.4.4 Analisis Eksperimen

Dari ketiga eksperimen yang telah dilakukan, berikut adalah beberapa hal yang dapat dilihat.

- *Pair* yang diyakini benar tergolong sedikit jika dibandingkan dengan total *pair* yang terkestraksi. Hal ini dapat disebabkan oleh nilai *threshold* yang didefinisikan, proses pembobotan, maupun *stopping condition*.
- *Pattern* yang sama akan menghasilkan total *pair* yang terkestraksi sama. Pada eksperimen 1 dan 2, hingga iterasi 3, total *pair* yang dihasilkan adalah sama akibat ekstraksi menggunakan *pattern* yang sama.
- Semakin banyak pasangan kata yang digunakan untuk membentuk *pattern*, maka semakin banyak pula *pattern* yang dihasilkan.
- Menurunkan sedikit nilai *threshold* dapat menambah banyak *pair* yang lolos filterisasi. Pada eksperimen 2, menurunkan *threshold* sebesar 0.05 meningkatkan jumlah *pair* hingga dua kali lipat. Hal tersebut dapat menunjukkan bahwa banyak *pair* yang nilai *threshold*-nya berada di ambang batas.
- *Stopping condition* dengan hanya menghitung jumlah *pair* baru tidak menjamin bahwa sudah tidak ada lagi *pair* benar.

5.5 Hasil Evaluasi Pair

Proses evaluasi *pair* dilakukan hanya terhadap *pair* yang diterima ke dalam korpus pasangan kata. Anotasi *pair* dilakukan oleh tiga anotator berbeda dengan daftar *pair* yang sama. Dari data hasil anotasi, akan dilihat akurasi tiap eksperimen yang telah dilakukan, akurasi berdasarkan *pattern* yang digunakan, tingkat persetujuan antar anotator, kemudian menganalisis data hasil.

Total sampel yang dianotasi adalah 514 *pair*, dimana sampel tersebut diambil dari gabungan ketiga percobaan. Anotator memberi nilai anotasi terhadap dua dimensi yaitu apakah *pair* benar memiliki relasi semantik hipernim-hiponim dan mengelompokkan berdasarkan kategorinya. Sayangnya, nilai yang diberikan antar anotator tidak selalu sama, untuk itu ingin diketahui tingkat persetujuan antar anotator. Tingkat persetujuan ketiga anotator dihitung menggunakan Fleiss' Kappa karena anotasi dilakukan oleh lebih dari dua anotator.

5.5.1 Hasil Anotasi Pair

Data yang telah dianotasi digunakan untuk mengetahui akurasi korpus pasangan kata relasi yang dihasilkan. Tabel 5.11 memperlihatkan perbandingan jumlah data yang dianotasi antar anotator. Kolum dalam tabel menyatakan jumlah data yang diberi label benar oleh n anotator. Misal '3 Benar' berarti kolum tersebut memperlihatkan jumlah data yang dianotasi benar oleh ketiga anotator. Kolum '1 Benar' memperlihatkan jumlah data yang dianotasi benar oleh hanya seorang anotator atau dapat diartikan juga jumlah data yang dilabeli benar oleh satu anotator dan salah oleh dua anotator.

Tabel 5.11: Perbandingan hasil anotasi *pair* antar anotator

3 Benar	2 Benar	1 Benar	0 Benar
345	83	52	33

Dari data di atas, dapat dihitung akurasi kebenaran sampel. Data yang memiliki labelnya tidak sama untuk ketiga anotator seperti kolum '2 Benar' dan '1 Benar', nilai kebenaran diambil menggunakan sistem *voting*. Akurasi total yang didapatkan dari seluruh data sampel adalah 0.83.

Selanjutnya, untuk mengevaluasi parameter *semi-supervised* yang dimodifikasi, perlu dihitung akurasi untuk setiap eksperimen sehingga dapat dibandingkan. Tabel 5.12 memperlihatkan akurasi *pair* untuk setiap eksperimen.

Tabel 5.12: Akurasi *pair* untuk setiap eksperimen

Eksperimen	Total <i>Pair</i>	Jumlah Sampel	Jumlah Sampel Benar	Akurasi
1	1432	289	233	0.80
2	3493	511	427	0.84
3	459	103	89	0.86

Data di atas menunjukkan bahwa menurunkan nilai *threshold* belum tentu memperburuk akurasi *pair* yang dihasilkan. Hal ini berarti persebaran *pair* yang salah

belum secara jelas dapat diketahui dengan pembobotan yang saat ini digunakan. Selain itu dapat diketahui pula bahwa *pair* yang hanya memperhatikan *single token* memiliki kualitas lebih baik dibanding *pair* yang memperbolehkan *multi token*.

5.5.2 Akurasi Pair Berdasarkan Pattern

Evaluasi *pair* dapat dilihat berdasarkan *pattern* yang membentuk *pair* tersebut. Tabel 5.13 memperlihatkan total *pair* yang dihasilkan dan akurasi untuk setiap *pattern*. *Pattern* yang dianalisis dalam tabel tersebut hanya *pattern* yang digunakan untuk proses ekstraksi *pair*. Total *pair* menyatakan jumlah *pair* yang terbentuk menggunakan *pattern* dalam seluruh eksperimen yang telah dilakukan. *Pair* diterima menyatakan total *pair* yang masuk ke dalam korpus pasangan kata relasi untuk seluruh eksperimen.

Tabel 5.13: Akurasi *pair* berdasarkan *pattern*

<i>Pattern</i>	Total <i>pair</i>	<i>Pair</i> diterima	Sampel	<i>Pair</i> benar	Akurasi
<hypernym> atau <hyponym>	164	8	5	2	0.4
<hypernym> seperti <hyponym> dan	136	38	7	7	1
<hypernym> termasuk <hyponym>	238	69	19	19	1
<hyponym> adalah <hypernym> yang	81892	2078	308	258	0.84
<hyponym> adalah sebuah <hypernym>	1910	36	7	5	0.71
<hyponym> menjadi <hypernym>	574	72	25	25	1
<hyponym> merupakan <hypernym>	27095	1508	237	202	0.85
<hyponym> merupakan <hypernym> yang	9715	754	132	114	0.86
<start> <hyponym> adalah <hypernym>	83319	2160	316	264	0.84
<start> <hyponym> merupakan <hypernym>	22618	1363	207	177	0.86

Data di atas menunjukkan sebagian besar *pattern* yang terpilih untuk proses *pattern matching* adalah *pattern* yang baik karena menghasilkan kumpulan *pair* dengan akurasi yang cukup tinggi. Namun, ada juga *pattern* terpilih yang nilai akurasinya buruk yaitu *pattern* '<hypernym> atau <hyponym>'.

5.5.3 Tingkat Persetujuan Anotator Pair

Dalam proses anotasi, tidak mungkin semua data dapat dianotasi ke dalam kategori yang sama oleh seluruh anotator. Perhitungan tingkat persetujuan dapat dilakukan dengan mencari nilai Fleiss' Kappa, Tingkat persetujuan diukur berdasarkan nilai anotasi data berlabel benar atau salah untuk seluruh sampel. Tiga anotator ($n = 3$) memberi penilaian terhadap 514 data sampel ($N = 514$) ke dalam dua label ($k = 2$) yaitu benar atau salah. Tabel 5.14 memaparkan langkah-langkah hingga didapatkan

nilai kappa. Sementara, tabel 5.15 adalah perhitungan nilai kappa berdasarkan lima kategori ($k = 5$) yang didefinisikan.

Tabel 5.14: Perhitungan tingkat persetujuan anotator berdasarkan label benar/salah *pair*

$sum P_i$	423.33
P_o	0.82
p_{True}	0.81
p_{False}	0.19
P_e	0.70
$Kappa$	0.42

Setelah diperoleh nilai P_o dan P_e , nilai Kappa dapat dihitung menggunakan rumus 2.1. Tingkat persetujuan ketiga anotator berdasarkan nilai kebenaran *pair* adalah 0.42. Nilai tersebut menunjukkan bahwa tingkat persetujuan antar anotator tergolong *moderate agreement*.

Tabel 5.15: Perhitungan tingkat persetujuan anotator berdasarkan kategori *pair*

$sum P_i$	329.33
P_o	0.64
p_{CC}	0.29
p_{IC}	0.52
p_{FF}	0.07
p_{FR}	0.10
p_{FP}	0.02
P_e	0.37

Nilai kappa yang dihasilkan jika dilihat dari anotasi berdasarkan kategori adalah 0.43. Hal tersebut menunjukkan bahwa tingkat persetujuan untuk kasus ini sama seperti sebelumnya yaitu tergolong *moderate agreement*.

5.5.4 Analisis Pair yang Dihasilkan

Dari hasil anotasi tersebut serta analisis kualitatif terhadap *pair* yang dihasilkan, berikut adalah beberapa hal yang didapatkan.

- *Pair* yang hanya terdiri dari *single token* memiliki nilai akurasi yang relatif lebih tinggi dibanding *multi token*.

- Dari evaluasi kualitatif terhadap *pair* yang dilabeli salah, tipe *kesalahan* yang banyak dijumpai adalah *false relation*. Sementara relasi semantik lain yang seharusnya merepresentasikan *pair* tersebut adalah relasi sinonim.
- *Pair* dengan benar dengan kategori instance-konsep banyak dijumpai pada *pair* yang mengandung *multi token*, dengan kata hiponim merupakan *Proper Noun*.
- Beberapa *pair* masih dapat dianggap benar walau dihilangkan token katanya, seperti (ballantine's, merek wiski) lebih tepat ditulis sebagai (ballantine's, wiski)
- Beberapa *pair* merupakan *Noun Phrase* seperti (rikard nordraak, komposer norwegia) dimana kata 'komposer' saja sebenarnya sudah cukup. Tambahan kata 'norwegia' dapat menambah informasi relasi antar kata seperti Rikard Nordraak berasal dari Norwegia.
- Beberapa *pair* memiliki token berlebih yang tidak dibutuhkan, seperti 'pe-sepak bola asal' yang kelebihan kata 'asal' atau 'aslinya paralegal' yang kelebihan kata 'aslinya'. Hal ini terjadi akibat upaya pembentukan *multi token*.
- Beberapa *pair* merupakan kata fiksi seperti nama karakter suatu cerita. Walau *pair* tersebut tidak salah, sulit untuk mengetahui kebenarannya.

5.6 Hasil Evaluasi Pattern

Evaluasi *pattern* dilakukan secara manual oleh dua anotator yang ahli dibidang linguistik. Seperti sudah dijelaskan sebelumnya, selain memberi penilaian kepada *pattern* yang dihasilkan oleh sistem, anotator juga membuat *pattern* manual untuk dibandingkan. Berikut adalah hasil *pattern* yang dibuat manual dan evaluasi *pattern* yang dibentuk sistem.

5.6.1 Pattern Buatan Manual

Lampiran 1 menampilkan daftar *pattern* leksikal yang dibentuk secara manual oleh anotator. Anotator mengamati kalimat-kalimat di dalam teks dokumen yang mengandung pasangan kata hipernim-hiponim kemudian membuat *pattern* yang dapat merepresentasikan relasi. Terdapat total 67 *pattern* leksikal manual yang dibentuk

oleh anotator. Tidak seperti *pattern* sistem dimana satu *pattern* hanya dapat mengandung tepat satu pasang *tag* hipernim-hiponim, beberapa *pattern* manual mengandung lebih dari satu *tag* hiponim.

Selanjutnya, *pattern* sistem dibandingkan dengan *pattern* manual tersebut. Satu *pattern* dapat dikategorikan sebagai *exact match*, *partial match*, atau *no match*. Tabel 5.16 memperlihatkan jumlah *pattern* yang masuk ke dalam setiap kategori untuk setiap iterasi.

Tabel 5.16: Kategori *pattern* sistem dibandingkan dengan *pattern* manual

Eksperimen	Exact Match	Partial Match	No Match
1	10	114	301
2	10	367	465
3	8	132	297

Jika dibandingkan dengan total *pattern* yang dihasilkan sistem, jumlah *pattern* buatan manual memang jauh lebih sedikit. Tabel diatas memperlihatkan bahwa *pattern* yang tergolong *exact match* masih sangat sedikit. Pada eksperimen 2 dan 3, walau total *pattern* yang dihasilkan berbeda, jumlah *pattern* yang merupakan *exact match* adalah sama. Hal ini berarti semakin banyak *pattern* yang dihasilkan belum tentu semakin baik. Kemudian, dari keseluruhan *pattern*, yang tergolong ke dalam *no match* hampir selalu mendominasi. Hal tersebut memperlihatkan bahwa *pattern* oleh sistem masih terlalu banyak yang hanya kebetulan terbentuk.

Data di atas kemudian digunakan untuk menghitung *precision pattern* yang digunakan untuk mengekstraksi pasangan kata dalam setiap eksperimen. Tabel 5.17 memperlihatkan *precision* untuk setiap eksperimen. Kolum ‘jumlah *pattern*’ menyatakan total *pattern* yang digunakan untuk mengekstraksi *pair* sementara kolum ‘*pattern* benar’ menyatakan jumlah *pattern* yang tergolong *exact match* atau *partial match*.

Tabel 5.17: Kategori *pattern* sistem dibandingkan dengan *pattern* manual

eksperimen	jumlah pattern	pattern benar	precision
1	8	6	0.75
2	8	7	0.875
3	6	5	0.83

Walau *pattern* yang digunakan untuk proses ekstraksi sangat sedikit, *pattern* dapat dikatakan berkualitas baik karena banyak yang merupakan anggota dari *pattern*

yang dibentuk manual oleh anotator. Hal tersebut ditunjukkan dari nilai *precision* yang cukup tinggi.

5.6.2 Hasil Anotasi Pattern

Dua anotator memberi penilaian terhadap 200 *pattern* terbaik yang dihasilkan pada eksperimen ke-1. Anotasi hanya dilakukan pada eksperimen ke-1 karena banyak variasi *pattern* yang dihasilkan antar eksperimen mirip. Selain itu, keterbatasan waktu dan tenaga juga menjadi salah satu alasan. Tabel 5.18 menampilkan perbandingan hasil anotasi antar anotator jika dilihat dari dimensi jumlah *pair* yang dihasilkan benar, sementara tabel 5.19 memaparkan perbandingan jika dilihat dari dimensi jumlah *pair* yang dihasilkan salah.

Tabel 5.18: Perbandingan hasil anotasi berdasarkan jumlah *pair* benar

Jumlah Benar	anotator 1		
anotator 2	kategori 1	kategori 2	kategori 3
kategori 1	83	5	3
kategori 2	17	4	27
kategori 3	10	1	50

Jika dilihat dari jumlah *pair* benar yang mungkin terekstrak oleh *pattern* tersebut, masih banyak *pattern* yang kualitasnya buruk (kategori 1).

Tabel 5.19: Perbandingan hasil anotasi berdasarkan jumlah *pair* salah

Jumlah Salah	anotator 1		
anotator 2	kategori 1	kategori 2	kategori 3
kategori 1	57	1	2
kategori 2	33	1	8
kategori 3	74	2	22

Dari tabel 5.19, sangat banyak ditemukan data dimana anotator pertama menganggap *pattern* menghasilkan sedikit *pair* salah (kategori 1) namun anotator dua menilai *pattern* menghasilkan banyak *pair* salah (kategori 3).

Selanjutnya tabel 5.20 menampilkan secara rinci anotasi untuk *pattern* yang digunakan pada seluruh eksperimen.

Tabel 5.20: Hasil anotasi *pattern* yang digunakan untuk ekstraksi *pair*

Pattern	anotator 1		anotator 2	
	benar	salah	benar	salah
<hypernym> atau <hyponym>	1	3	1	2
<hypernym> seperti <hyponym>	3	1	3	1
<hypernym> termasuk <hyponym>	3	1	1	3
<hyponym> adalah <hypernym> yang	3	1	3	1
<hyponym> adalah sebuah <hypernym>	3	1	3	1
<hyponym> menjadi <hypernym>	3	1	2	2
<hyponym> merupakan <hypernym>	3	1	3	1
<hyponym> merupakan <hypernym> yang	3	1	3	1
<start> <hyponym> adalah <hypernym>	3	1	3	1

Data diatas mendukung hasil yang ditampilkan pada tabel 5.13 dimana *pattern* ‘<hypernym> atau <hyponym>’ adalah yang terburuk dari seluruh *pattern* yang digunakan untuk proses pembentukan *pair*. *Pattern* tersebut dianggap akan banyak menghasilkan *pair* yang berlabel salah. Sementara sebagian besar *pattern* lain yang digunakan untuk proses ekstraksi sudah cukup baik karena dianggap menghasilkan banyak *pair* benar dan sedikit *pair* salah.

5.6.3 Tingkat Persetujuan Anotator Pattern

Dari data pada tabel 5.18 dan 5.19, dapat dihitung tingkat persetujuan antar anotator. Perhitungan nilai persetujuan berdasarkan Cohen’s Kappa karena jumlah anotator tepat dua. Tabel menampilkan nilai Kappa berdasarkan jumlah *pair* terbentuk benar maupun salah.

Tabel 5.21: Cohen’s Kappa untuk setiap dimensi

	Jumlah benar	Jumlah Salah
P_o	0.685	0.4
$p_{kategori1}$	0.25	0.25
$p_{kategori2}$	0.012	0.0042
$p_{kategori3}$	0.12	0.078
P_e	0.38	0.33
$kappa$	0.49	0.11

Jika dilihat dari jumlah *pair* yang terbentuk benar, maka tingkat persetujuan antar anotator tergolong moderate agreemnet. Sementara jika dilihat dari jumlah

pair yang terbentuk salah, tingkat persetujuan adalah *slight agreement*. Hal tersebut menunjukkan bahwa sangat sulit bagi anotator untuk membayangkan apakah satu *pattern* dapat menghasilkan *pair* salah.

5.6.4 Analisis Pattern

Ekstraksi *pattern* dibatasi dengan beberapa aturan yang diharapkan dapat menghasilkan *pattern* dengan kualitas baik. Sistem sudah dapat secara otomatis menghasilkan *pattern* yang tergolong baik untuk merepresentasikan relasi semantik hipernim-hiponim seperti ‘<hyponym> adalah <hypernym>’, ‘<hyponym> adalah <hypernym> yang’, ‘<hyponym> merupakan <hypernym>’ dan lainnya. Namun, masih banyak kekurangan dari *pattern* yang dihasilkan. Berikut adalah beberapa kekurangan *pattern* yang terbentuk serta analisa mengapa hal tersebut dapat terjadi.

- Belum dapat membentuk *pattern* yang mengandung lebih dari satu *tag* *hiponim*.

Banyak kalimat yang mengandung lebih dari satu kata *hiponim*, namun saat ini *pattern* yang terbentuk belum dapat membuatnya. Hal ini karena pada masa awal implementasi, ditemukan beberapa kalimat yang mengandung dua pasangan kata relasi berbeda dalam satu kalimat. Untuk mencegah ambiguitas dibatasi satu kalimat hanya akan di-*tag* dengan satu pasang kata relasi. Kedepannya, hal ini dapat diatasi dengan mengubah batasan sehingga dalam satu kalimat boleh di-*tag* dengan lebih dari satu pasang kata relasi asal kata hipernimnya sama.

- Beberapa *pattern* yang kurang baik secara semantik.

Beberapa *pattern* yang dihasilkan sistem seperti ‘<hypernym> dan <hyponym>’ dan ‘<hypernym> atau <hyponym>’ kurang cocok jika digunakan dalam *pattern matching*. Hal ini disebabkan kata ‘dan’ dan ‘atau’ memuat relasi yang bersifat simetris. Sementara hipernim-hiponim merupakan relasi yang hanya memiliki sifat transitif.

- *Pattern* yang tergolong dalam lebih dari satu relasi.

Dalam beberapa penelitian lain, satu *pattern* bisa merepresentasikan beberapa relasi semantik. Terutama *pattern* yang berukuran pendek seperti yang dihasilkan sistem. Penelitian ini hanya fokus pada relasi semantik hipernim-hiponim sehingga tidak adanya pembandingan antar *pattern* yang merepresentasikan relasi semantik lain. Hal ini menjadi hambatan dalam menentukan

apakah *pattern* dapat dikatakan baik.

Cara membentuk *pattern* leksikal yang baik masih perlu diteliti lebih lanjut. Proses lain seperti generalisasi *pattern* perlu diimplementasi agar satu *pattern* mengandung informasi yang lebih kaya.

5.7 Evaluasi Skenario Eksperimen

Dari tiga eksperimen yang telah dilakukan, eksperimen 3 memberi nilai akurasi terbaik (Tabel 5.12). Hal tersebut membuktikan bahwa *pair* yang hanya *single token* lebih tinggi kemungkinan benar dibanding *pair* yang *multi token*. Eksperimen tersebut juga membuktikan bahwa metode pembentuk *multi token* yang sangat ini digunakan masih perlu peningkatan. Namun skenario ini tidak dapat dikatakan yang terbaik karena jumlah *pair* yang dihasilkan sangat sedikit.

Kemudian, dari hasil perbandingan eksperimen ke-1 dan eksperimen ke-2, menurunkan nilai *threshold* tidak selalu memperburuk kualitas *pair* yang dihasilkan. Pada eksperimen 2, nilai akurasi meningkat dibanding eksperimen 1. Hal ini dapat disebabkan oleh pemilihan sampel yang digunakan untuk proses anotasi. Akurasi *pair* tergantung dari *pattern* yang membentuk *pair* tersebut. Jika banyak *pattern* baik yang mengekstrak *pair*, maka besar kemungkinan *pair* tersebut juga berkualitas baik. Pada eksperimen 1, *pattern* terakhir yang digunakan yaitu '<hyponym>' atau '<hyponym>' dapat dikatakan buruk dan hal ini mempengaruhi akurasi total untuk eksperimen tersebut.

Dalam penelitian ini, hasil masih sangat tergantung dengan pendefinisian segala parameter *semi-supervised* yang digunakan. Dari proses pembentukan *seed* dengan menerapkan sejumlah filterisasi, proses pengurutan *pattern*, pemilihan banyak *pattern* yang digunakan, pembentukan *multi token*, pembobotan *pair* yang terekstrak, filterisasi *pair*, serta *stopping condition* masih banyak yang parameter yang didefinisikan secara manual berdasarkan hasil pengamatan kualitatif. Penelitian ini masih banyak memerlukan berbagai eksperimen lain dan pengembangan lebih lanjut agar dapat diketahui arsitektur *semi-supervised* terbaik.

BAB 6

KESIMPULAN DAN SARAN

6.1 Kesimpulan

Korpus pasangan kata relasi semantik dibutuhkan untuk digunakan dalam berbagai penelitian. Relasi kata hipernim-hiponim adalah relasi yang menghubungkan antara kata yang lebih umum dan kata yang lebih khusus. Proses pembangunan korpus dapat dilakukan dengan berbagai metode, salah satu yang cukup sering dan efisien adalah dengan pendekatan berbasis *pattern* yaitu *pattern matching* dan *pattern extraction*. Metode berbasis *pattern* dengan memanfaatkan korpus Wikipedia telah banyak dilakukan dalam beberapa penelitian sebelumnya.

Pembangunan korpus dilakukan secara bertahap menggunakan pendekatan *semi-supervised learning*. Secara umum, terdapat empat tahap utama dalam arsitektur *semi-supervised* yang diusulkan. Pertama adalah *pre-processing* data yang terdiri dari pembentukan *seed* dan pengolahan data Wikipedia. Kemudian *pattern* dibentuk dengan melakukan *sentence tagging* dari *seed* ke kalimat Wikipedia dan dilanjutkan dengan *pattern extraction* dari kalimat yang sudah memiliki *tag*. Selanjutnya *pair* baru diekstrak menggunakan *pattern* yang sudah terbentuk terhadap korpus kalimat Wikipedia. Proses evaluasi dilakukan secara kolektif pada akhir eksperimen. Dalam implementasi *cycle semi-supervised*, banyak parameter yang didefinisikan sendiri berdasarkan pengamatan kualitatif.

Dari banyak *seed* yang dihasilkan dari WordNet Bahasa, hanya 140 *pair* yang masuk ke dalam korpus pasangan kata relasi. Hal ini disebabkan karena hanya *seed* yang membentuk lima *pattern* utama yang dapat masuk ke dalam korpus. Proses ini dilakukan guna memfilterisasi banyaknya *seed* salah yang terbentuk pada pembangunan *seed*. Walaupun *seed* yang diambil sangat sedikit, *seed* tersebut dapat dikatakan baik dimana akurasi mencapai 0.9. Hal ini menunjukkan bahwa masih terdapat beberapa *seed* salah yang dihasilkan akibat kekurangan yang dimiliki oleh WordNet Bahasa.

Pattern yang dihasilkan oleh sistem dapat dikatakan terlalu banyak yang tidak semua merepresentasikan relasi hipernim-hiponim yang umum. Jika dibandingkan dengan *pattern* manual buatan anotator, *pattern* yang tergolong *exact match* sangat sedikit. Eksperimen ke-1 dan ke-2 memperlihatkan bahwa semakin banyak jumlah *pattern* yang dihasilkan tidak meningkatkan kualitas *pattern*. Proses evaluasi ke-

baikan *pattern* masih sangat sulit dilakukan. Hal ini terlihat dari rendahnya nilai persetujuan antar anotator jika dilihat dari jumlah *pair* salah yang mungkin terbentuk. Walau masih banyak kekurangan, *pattern* yang digunakan untuk proses *pattern matching* dapat dikatakan baik karena berhasil menghasilkan korpus pasangan kata yang memiliki akurasi cukup tinggi. Selain itu, jika dilihat dari *pattern* yang digunakan dalam proses ekstraksi *pair*, *precision* cukup tinggi dengan nilai terbesar mencapai 0.875.

Selanjutnya, *pair* yang berhasil diekstraksi berjumlah banyak, sayangnya *pair* yang diyakini benar sangatlah sedikit. Hal tersebut dipengaruhi nilai *threshold*, metode pembobotan, serta *stopping condition* untuk *cycle semi-supervised*. Sementara, tipe kesalahan yang banyak dijumpai dalam *pair* adalah pasangan kata merupakan relasi bukan hipernim-hiponim dengan relasi yang populer adalah relasi sinonim. Hal ini menunjukkan bahwa *pattern* yang merepresentasikan relasi hipernim-hiponim dan relasi sinonim beberapa sama.

Metode *pattern matching* dan *extraction* dapat digunakan untuk mengekstraksi kata Bahasa Indonesia. Metode ini menghasilkan *pair* yang cukup baik dimana untuk setiap eksperimen akurasinya melebihi 0.80. Jumlah *pair* yang terekstrak dan akurasinya lebih dipengaruhi oleh *pattern* yang membentuk *pair* tersebut. Sementara akurasi *pair* yang dihasilkan untuk setiap eksperimen lebih dipengaruhi oleh *pattern* yang digunakan untuk ekstraksi. Jika *pattern* yang digunakan adalah *pattern* yang berkualitas baik, maka *pair* yang dihasilkanpun memiliki nilai akurasi yang tinggi. Perubahan skenario setiap eksperimen lebih mempengaruhi urutan *pattern* yang dihasilkan.

Penelitian pembangunan korpus pasangan kata relasi semantik hipernim-hiponim ini memiliki potensi untuk dikembangkan. *Pair* yang dapat dikatakan cukup baik mre. Namun, masih perlu dilakukan berbagai modifikasi maupun eksperimen lain yang dapat meningkatkan kualitas baik *pattern* maupun *pair* yang dihasilkan.

6.2 Saran

Dari hasil penelitian ini, berikut adalah beberapa saran yang dapat diberikan untuk penelitian berikutnya.

1. Proses pembentukan kata yang merupakan *multi token* saat ini masih sangat sederhana yaitu hanya dengan menggabungkan kata-kata yang memiliki *POS tag* sama. Selanjutnya dapat diteliti cara yang lebih baik sehingga kata *multi token* yang dihasilkan tidak mengandung token berlebih.

2. Mengubah perhitungan pembobotan *pair*. Proses pembobotan yang digunakan saat ini hanya memperhatikan jumlah *pattern* yang membentuk *pair* dan memanfaatkan pemodelan *word embedding* untuk mengetahui kemiripan antar kata kemudian dicari rata-ratanya. Pembobotan ini didefinisikan sendiri berdasarkan analisis kualitatif yang dilakukan, namun belum diketahui apakah pembobotan ini sudah ideal. Penelitian selanjutnya dapat mengubah proses pembobotan yang lebih baik dalam merepresenstasikan kebaikan suatu *pair*.
3. Pembentukan *pattern* yang lebih baik. *Pattern* yang saat ini terbentuk hanya dapat menyimpan informasi mengenai tepat satu pasangan kata hipernim-hiponim. Sementara, jika dilihat dari *pattern* yang dibentuk secara manual, banyak *pattern* yang mengandung lebih dari satu *tag* hiponim. Pembentukan *pattern* perlu dimodifikasi untuk dapat menghasilkan *pattern* tersebut. Dilihat dari proses pembentukan *pattern*, cara-cara lain yang dapat dicoba adalah menggabungkan pendekatan yang memperhatikan n kata diawal dan n kata diakhir. Selanjutnya dari seluruh *pattern* leksikal yang terbentuk dapat dilakukan generalisasi sehingga *pattern* yang dihasilkan lebih representatif. Proses generalisasi *pattern* dapat memanfaatkan informasi *POS tag* kata-kata dalam *pattern* tersebut.
4. Ekstraksi pasangan kata relasi lain. Dari penelitian ini, dilihat bahwa tidak semua *pattern* yang dihasilkan merepresentasikan relasi hipernim-hiponim dengan baik. Beberapa *pattern* terlihat lebih cocok merepresentasikan relasi semantik lain. *Pair* salah yang dihasilkanpun banyak yang merupakan *pair* salah namun mengandung relasi semantik lain. Hal ini dapat disebabkan satu *pattern* merepresentasikan beberapa relasi lain. Penelitian yang secara sekaligus mengekstrak pasangan kata untuk beberapa relasi semantik dapat dilakukan untuk membandingkan *pattern* antar relasi tersebut.
5. Mengembangkan arsitektur *semi-supervised* yang lebih baik. Arsitektur *semi-supervised* yang digunakan saat ini dikembangkan sendiri dengan metode *Bootstrapping* sebagai dasarnya. Pengembangan selanjutnya dapat memodifikasi arsitektur tersebut dengan mengubah parameter-parameter yang didefinisikan sendiri seperti jumlah *pattern* yang digunakan tiap iterasi, nilai *threshold*, metode filterisasi, serta *stopping condition*.
6. Jika evaluasi dilakukan dengan cara *sampling*, sebagiknya dilakukan tidak hanya sekali. Penelitian hanya melakukan *sampling* sekali sehingga hasil akurasi *pair* dipengaruhi data yang menjadi sampel.

DAFTAR REFERENSI

- Adriani, M., Manurung, R., dan Pisceldo, F. (2009). Statistical based part of speech tagger for bahasa indonesia. In *Proceedings of the 3rd International MALINDO Workshop*.
- Arnold, P. dan Rahm, E. (2014). Extracting semantic concept relations from wikipedia. In *Proceedings of the 4th International Conference on Web Intelligence, Mining and Semantics (WIMS14)*, page 26. ACM.
- Atkins, S., Clear, J., dan Ostler, N. (1992). Corpus design criteria. *Literary and linguistic computing*, 7(1):1–16.
- Bach, N. dan Badaskar, S. (2007). A review of relation extraction. *Literature review for Language and Statistics II*.
- Bikel, D. M., Schwartz, R., dan Weischedel, R. M. (1999). An algorithm that learns what's in a name. *Machine learning*, 34(1):211–231.
- Denoyer, L. dan Gallinari, P. (2006). The wikipedia xml corpus. In *International Workshop of the Initiative for the Evaluation of XML Retrieval*, pages 12–19. Springer.
- Dinakaramani, A., Rashel, F., Luthfi, A., dan Manurung, R. (2014). Designing an indonesian part of speech tagset and manually tagged indonesian corpus. In *Asian Language Processing (IALP), 2014 International Conference on*, pages 66–69. IEEE.
- Fellbaum, C. (1998). *WordNet*. Wiley Online Library.
- Francis, W. N. dan Kucera, H. (1979). Brown corpus manual. *Brown University*, 15.
- Hearst, M. A. (1992). Automatic acquisition of hyponyms from large text corpora. In *Proceedings of the 14th conference on Computational linguistics-Volume 2*, pages 539–545. Association for Computational Linguistics.
- Huang, Z., Thint, M., dan Qin, Z. (2008). Question classification using head words and their hypernyms. In *Proceedings of the Conference on Empirical Methods*

- in Natural Language Processing*, pages 927–936. Association for Computational Linguistics.
- Jurafsky, D. dan James, H. (2000). *Speech and language processing an introduction to natural language processing, computational linguistics, and speech*.
- Landis, J. R. dan Koch, G. G. (1977). The measurement of observer agreement for categorical data. *biometrics*, pages 159–174.
- Manning, C. D., Raghavan, P., Schütze, H., et al. (2008). *Introduction to information retrieval*, volume 1. Cambridge university press Cambridge.
- Marcus, M. P., Marcinkiewicz, M. A., dan Santorini, B. (1993). Building a large annotated corpus of english: The penn treebank. *Computational linguistics*, 19(2):313–330.
- Margaretha, E. dan Manurung, R. (2008). Comparing the value of latent semantic analysis on two english-to-indonesian lexical mapping tasks. In *Australasian Language Technology Association Workshop 2008*, volume 6, pages 88–96.
- Mikolov, T., Sutskever, I., Chen, K., Corrado, G. S., dan Dean, J. (2013). Distributed representations of words and phrases and their compositionality. In *Advances in neural information processing systems*, pages 3111–3119.
- Miller, G. A. (1995). Wordnet: a lexical database for english. *Communications of the ACM*, 38(11):39–41.
- Noor, N. H. B. M., Sapuan, S., Bond, F., et al. (2011). Creating the open wordnet bahasa. In *PACLIC*, pages 255–264.
- Prakash, V. J. dan Nithya, D. L. (2014). A survey on semi-supervised learning techniques. *arXiv preprint arXiv:1402.4645*.
- Putra, D. D., Arfan, A., dan Manurung, R. (2008). Building an indonesian wordnet. In *Proceedings of the 2nd International MALINDO Workshop*, pages 12–13.
- Riloff, E., Jones, R., et al. (1999). Learning dictionaries for information extraction by multi-level bootstrapping. In *AAAI/IAAI*, pages 474–479.
- Riloff, E., Wiebe, J., dan Wilson, T. (2003). Learning subjective nouns using extraction pattern bootstrapping. In *Proceedings of the seventh conference on Natural language learning at HLT-NAACL 2003-Volume 4*, pages 25–32. Association for Computational Linguistics.

- Ruiz-Casado, M., Alfonseca, E., dan Castells, P. (2005). Automatic extraction of semantic relationships for wordnet by means of pattern learning from wikipedia. In *International Conference on Application of Natural Language to Information Systems*, pages 67–79. Springer.
- Setya, K. N. (2016). Pengembangan korpus textual entailment bahasa indonesia menggunakan data wikipedia revision history dengan metode co-training.
- Sumida, A. dan Torisawa, K. (2008). Hacking wikipedia for hyponymy relation acquisition. In *IJCNLP*, volume 8, pages 883–888. Citeseer.
- Thelen, M. dan Riloff, E. (2002). A bootstrapping method for learning semantic lexicons using extraction pattern contexts. In *Proceedings of the ACL-02 conference on Empirical methods in natural language processing-Volume 10*, pages 214–221. Association for Computational Linguistics.
- Toutanova, K., Klein, D., Manning, C. D., dan Singer, Y. (2003). Feature-rich part-of-speech tagging with a cyclic dependency network. In *Proceedings of the 2003 Conference of the North American Chapter of the Association for Computational Linguistics on Human Language Technology-Volume 1*, pages 173–180. Association for Computational Linguistics.
- Zesch, T., Gurevych, I., dan Mühlhäuser, M. (2007). Analyzing and accessing wikipedia as a lexical semantic resource.

LAMPIRAN

LAMPIRAN 1 : PATTERN BUATAN MANUAL

Berikut adalah daftar *pattern* yang dibentuk secara manual oleh anotator.

- <hypernym> adalah kumpulan dari <hyponym>
- <hypernym> antara lain adalah <hyponym>, <hyponym>, dan <hyponym>
- <hypernym> dapat dibedakan menjadi <hyponym>
- <hypernym> lainnya, seperti <hyponym> dan <hyponym>
- <hypernym> seperti <hyponym>
- <hypernym> terdiri dari <hyponym>, <hyponym>, dan <hyponym>
- <hypernym> terdiri dari beberapa bagian, seperti <hyponym>, <hyponym>, dan <hyponym>
- <hypernym> terutama <hyponym> yang
- <hypernym>, khususnya <hyponym>, adalah
- <hypernym>, misalnya <hyponym>
- <hypernym>, misalnya <hyponym> dan <hyponym>
- <hypernym>, terutama <hyponym>, adalah
- <hyponym> adalah <hypernym>
- <hyponym> adalah <hypernym> dari
- <hyponym> adalah <hypernym> dengan
- <hyponym> adalah <hypernym> yang berhubungan dekat dengan <hyponym>
- <hyponym> adalah <hypernym> yang bersifat
- <hyponym> adalah bagian dari <hypernym> yang
- <hyponym> adalah salah satu <hypernym>

- <hyponym> adalah sebuah <hypernym> yang
- <hyponym> adalah sejenis <hypernym> dengan
- <hyponym> adalah suatu <hypernym>
- <hyponym> atau <hyponym> adalah suatu jenis <hypernym> yang
- <hyponym> berarti <hypernym>
- <hyponym> dan <hyponym> dianggap sebagai <hypernym>
- <hyponym> dan <hyponym> merupakan <hypernym> yang
- <hyponym> dan berbagai <hyponym> lainnya adalah <hypernym> yang
- <hyponym> dan sejumlah <hyponym> lainnya termasuk ke dalam kategori <hypernym>
- <hyponym> dapat digolongkan ke dalam <hypernym>
- <hyponym> dapat dimasukkan ke dalam kategori <hypernym> dan <hypernym>
- <hyponym> dianggap sebagai <hypernym> karena
- <hyponym> dikenal juga sebagai <hypernym>
- <hyponym> disebut sebagai <hypernym> yang
- <hyponym> ialah <hypernym>
- <hyponym> menjadi <hypernym> apabila
- <hyponym> menjadi <hypernym> yang
- <hyponym> menjadi salah satu bagian dari <hypernym> karena
- <hyponym> merujuk pada <hypernym>
- <hyponym> merujuk pada <hypernym> yang
- <hyponym> merupakan <hypernym>
- <hyponym> merupakan <hypernym> yang
- <hyponym> merupakan suatu <hypernym> yang

- <hyponym> secara khusus menjadi sebutan bagi <hypernym> yang
- <hyponym> termasuk <hypernym> yang
- <hyponym> termasuk ke dalam <hypernym> yang
- <hyponym> termasuk ke dalam kategori <hypernym>
- <hyponym> termasuk ke dalam salah satu <hypernym> yang
- <hyponym> tersebut merupakan <hypernym>
- Beberapa <hypernym> seperti <hyponym>
- Beberapa contoh <hypernym> lainnya adalah <hyponym>
- Beberapa jenis dari <hypernym> adalah <hyponym> dan <hyponym>
- Berbagai <hypernym> seperti <hyponym>
- Contoh dari <hypernym> adalah <hyponym>
- Contoh dari <hypernym>, yaitu <hyponym>, <hyponym>, dan <hyponym>
- Istilah umum dari <hyponym> adalah <hypernym>
- Jenis <hypernym> yang paling banyak dikenal adalah <hyponym>
- Jenis-jenis <hypernym> antara lain <hyponym> dan <hyponym>
- Salah satu <hypernym> adalah <hyponym>
- Salah satu <hypernym> yang mirip dengan <hyponym> adalah <hyponym>
- Salah satu contoh dari <hypernym> adalah <hyponym>
- Sebagai salah satu <hypernym>, <hyponym>
- Sebagai sebuah <hypernym>, <hyponym> merupakan
- Secara umum, <hyponym> merupakan <hypernym> yang dapat
- Selain <hyponym>, <hyponym> juga menjadi <hypernym> yang
- Terdapat banyak <hypernym>, seperti <hyponym>
- Terdapat beberapa contoh <hypernnym>, di antaranya <hyponym>, <hyponym>, dan <hyponym>
- Walaupun <hyponym> adalah <hypernym>, tetapi